Rapport de Comparaison des Modèles de Topics

Contents

Résumé . . . 2
1. Description du Corpus . . . 2
  1.1 Vue d'ensemble du jeu de données . . . 2
  1.2 Couverture Temporelle . . . 3
  1.3 Top 10 Artistes par Nombre de Documents . . . 3
2. Description des Modèles Individuels . . . 4
  2.1 BERTopic . . . 4
  2.2 LDA . . . 10
  2.3 IRAMUTEQ . . . 16
3. Analyse Comparative . . . 18
  3.1 Q1 : Les modèles capturent-ils la même structure ? . . . 18
  3.2 Q2 : Les modèles séparent-ils les artistes ? . . . 23
  3.3 Q3 : Les modèles capturent-ils l'évolution temporelle ? . . . 23
  3.4 Q4 : Quelle est la distinctivité lexicale des topics ? . . . 24
  3.5 Q5 : Quelle est l'homogénéité lexicale des topics ? . . . 25
4. Synthèse et Conclusions . . . 32
  Principales Conclusions . . . 32
5. Références Méthodologiques . . . 33
  Métriques d'Accord de Clustering . . . 33
  Mesures d'Association . . . 33
  Théorie de l'Information . . . 33
  Distance Intertextuelle . . . 34
  Cohérence des Topics . . . 34
  Validation de Clusters . . . 34
  Modélisation de Topics . . . 34
Annexes . . . 34
  A. Détails des Runs . . . 34
  B. Comparaison Mathématique : Labbé vs Jensen-Shannon . . . 34

Généré le: 2026-03-18 18:20:44

Répertoire de sortie: `/home/robin/Code_repo/psycholinguistic2125/JADT_rap_fr/results/comp`

Résumé

Ce rapport présente une comparaison approfondie de trois approches de modélisation de topics appliquées à un corpus de paroles de rap français : **BERTopic** (embeddings neuronaux), **LDA** (modèle génératif probabiliste), et **IRAMUTEQ** (classification lexicale par la méthode ALCESTE de Reinert). L'analyse se décompose comme suit :

1. **Description du corpus** : caractérisation statistique du corpus (nombre de documents, artistes, couverture temporelle, distribution par décennie).
2. **Description des modèles individuels** : paramètres, métriques de qualité (cohérence C_v, silhouette), distribution des topics et séparation des artistes pour chaque modèle.
3. **Q1 — Accord entre modèles** : évaluation de la similarité des clusterings à l'aide de l'ARI (Hubert & Arabie, 1985), la NMI (Strehl & Ghosh, 2002) et l'AMI (Vinh et al., 2010), avec analyse des correspondances inter-topics.
4. **Q2 — Séparation des artistes** : mesure de l'association artiste-topic par le V de Cramér (Cramér, 1946) et analyse des résidus de Pearson standardisés.
5. **Q3 — Dynamique temporelle** : analyse de la variance des distributions de topics dans le temps et de la divergence de Jensen-Shannon entre périodes biannuelles.
6. **Q4 — Distinctivité lexicale** : évaluation du chevauchement du vocabulaire entre topics par la distance de Jaccard et analyse inter-modèles.
7. **Q5 — Homogénéité intra-topic** : mesure de la cohérence lexicale des clusters par les distances de Labbé (Labbé & Labbé, 2001) et de Jensen-Shannon (Lin, 1991), calculées sur des documents tokenisés avec spaCy.
8. **Synthèse et recommandations** : bilan comparatif des trois modèles et recommandations d'usage.

---

1. Description du Corpus

Cette section présente une vue d'ensemble du corpus de paroles de rap français utilisé pour la modélisation de topics. Le corpus est constitué de couplets individuels extraits de chansons, avec des métadonnées incluant l'artiste, le titre et l'année.

1.1 Vue d'ensemble du jeu de données

Métrique	Valeur
Documents totaux (couplets)	115,805
Période couverte	1992 - 2023
Artistes uniques	605
Année moyenne	2014.7
Année médiane	2017
Docs moyens par artiste	191.4
Docs médians par artiste	137
Artiste le plus prolifique	JuL (2,878 docs)

1.2 Couverture Temporelle

Le corpus couvre plus de trois décennies de rap français, de l'ère pionnière des années 1990 à la scène contemporaine.

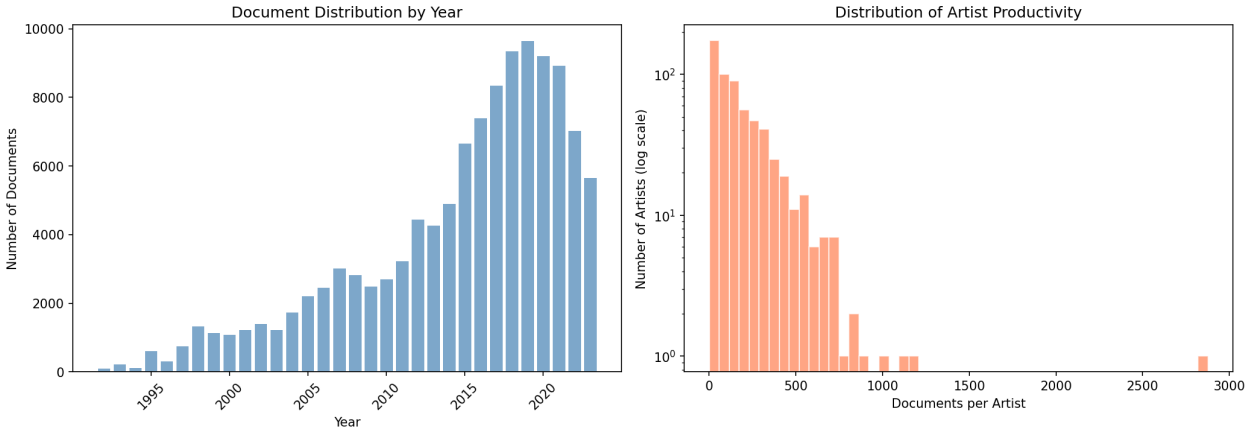

Figure 1: Distribution

Figure 1.1 : Gauche - Nombre de documents par année. Droite - Distribution de la productivité des artistes (échelle log).

Figure 1.2 : Distribution du corpus par décennie.

Décennie	Documents	% du Corpus
1990s	4,517	3.9%
2000s	19,605	16.9%
2010s	60,895	52.6%
2020s	30,788	26.6%

1.3 Top 10 Artistes par Nombre de Documents

Rang	Artiste	Documents	% du Corpus	% Cumulatif
1	JuL	2,878	2.5%	2.5%
2	La Fouine	1,191	1.0%	3.5%
3	Rohff	1,095	0.9%	4.5%
4	Sexion d'Assaut	1,023	0.9%	5.3%
5	Alkpote	889	0.8%	6.1%
6	Naps	854	0.7%	6.8%
7	Disiz	849	0.7%	7.6%
8	Swift Guad	797	0.7%	8.3%
9	IAM	745	0.6%	8.9%
10	Sinik	744	0.6%	9.6%

Concentration du corpus : Les 10 premiers artistes représentent 9.6% du corpus, indiquant une distribution d'artistes diverse.

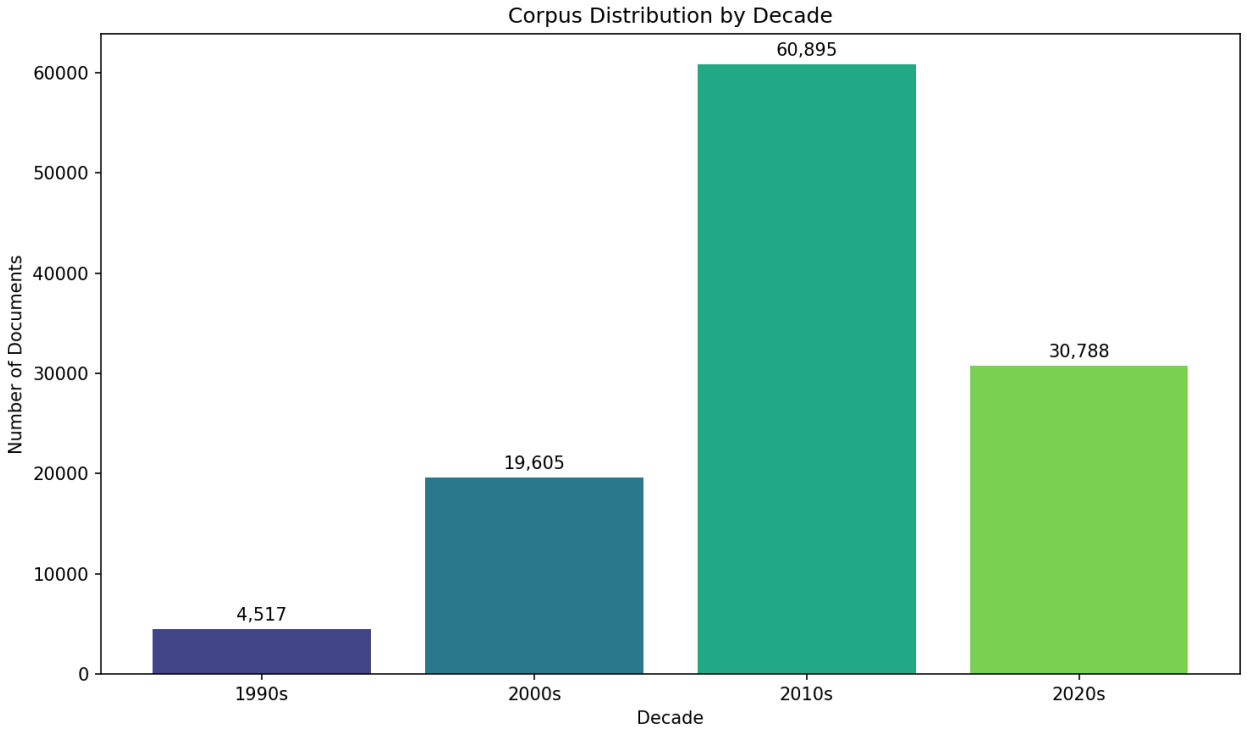

Figure 2: Decades

---

2. Description des Modèles Individuels

Cette section présente la configuration, les métriques de qualité et les topics découverts par chaque modèle. Nous incluons les visualisations spécifiques à chaque modèle pour contextualiser l'analyse comparative.

2.1 BERTopic

Dossier du run: `results/BERTopic/run_20260126_141647_mpnet`

BERTopic (Grootendorst, 2022) est un modèle de topics neuronal utilisant des embeddings de transformers pour la représentation des documents, UMAP pour la réduction de dimensionnalité, et le clustering. Les topics sont représentés via pondération c-TF-IDF, avec labellisation optionnelle par OpenAI et KeyBERT.

Paramètres

Paramètre	Valeur
embedding_model	`sentence-transformers/all-mpnet-base-v2`
embedding_key	`mpnet`

Paramètre	Valeur
clustering_algorithm	`kmeans`
n_clusters	`20`
hdbscan_params	`None`
agglomerative_params	`None`
umap_params	n_neighbors=15, n_components=5, min_dist=0.0, metric=cosine, random_state=42
num_words_per_topic	`30`
use_openai	`True`
include_keybert	`True`
interactive_html	`True`

Qualité du Clustering

Métrique	Valeur	Interprétation
Silhouette (UMAP)	0.1717	Modéré

Le score de silhouette (Rousseeuw, 1987) mesure la séparation des clusters.

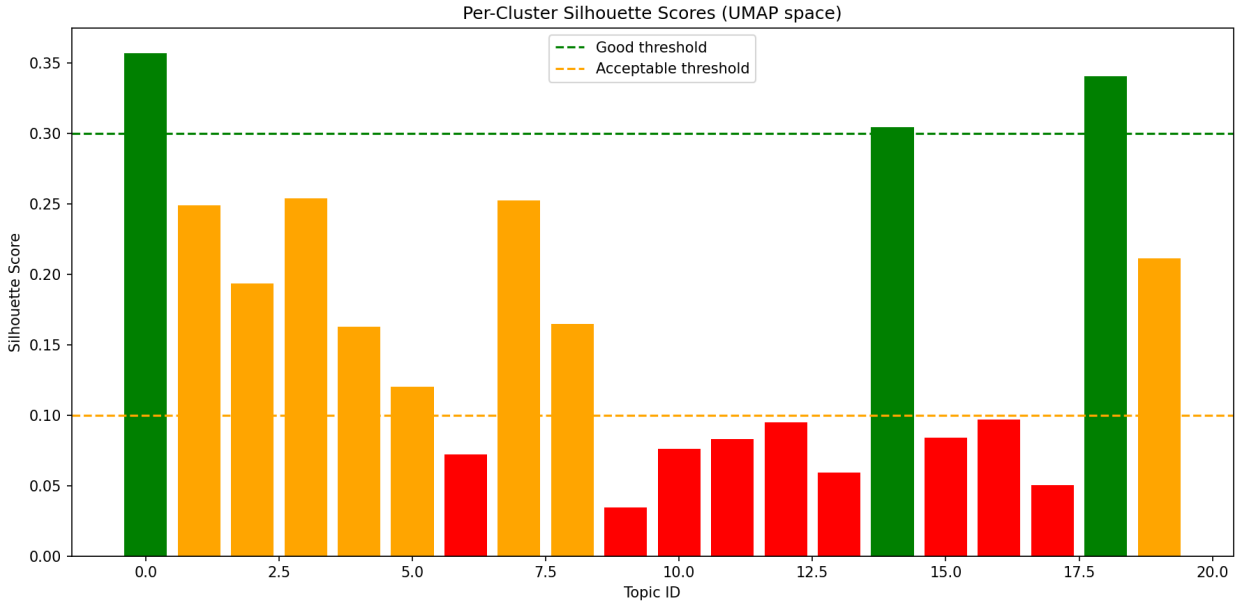

Figure 3: Silhouette

Distribution des Topics

Métrique	Valeur	Interprétation
Nombre de topics	20	-
Ratio d'imbalance	2.34	Modérément équilibré
Entropie de distribution	0.992	Quasi uniforme

Définitions des métriques :

- **Ratio d'imbalance** = max(compte_topic) / min(compte_topic). Mesure l'inégalité des tailles de topics.
- **Entropie de distribution** (normalisée) = -Σ(p_i × log(p_i)) / log(n_topics). Intervalle [0,1] : 1 = uniforme.

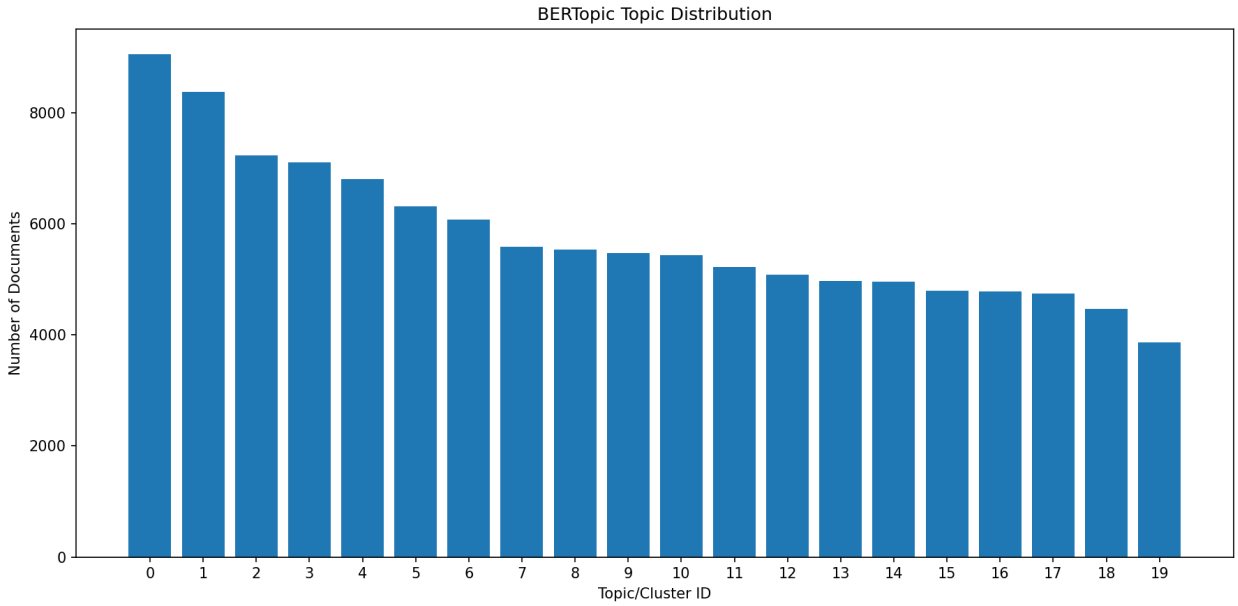

Figure 4: Topic Distribution

Distribution des documents par topic.

Séparation des Artistes

Métrique	Valeur	Description
% Spécialistes	2.2%	Artistes avec >50% dans un topic
% Modérés	11.5%	Artistes avec 25-50% dans le topic dominant
% Généralistes	86.3%	Artistes répartis sur plusieurs topics
Indice de spécialisation	0.168	Concentration moyenne
Divergence JS	0.451	Divergence des profils d'artistes

Heatmap de distribution des artistes par topic.

Profils de spécialisation des artistes.

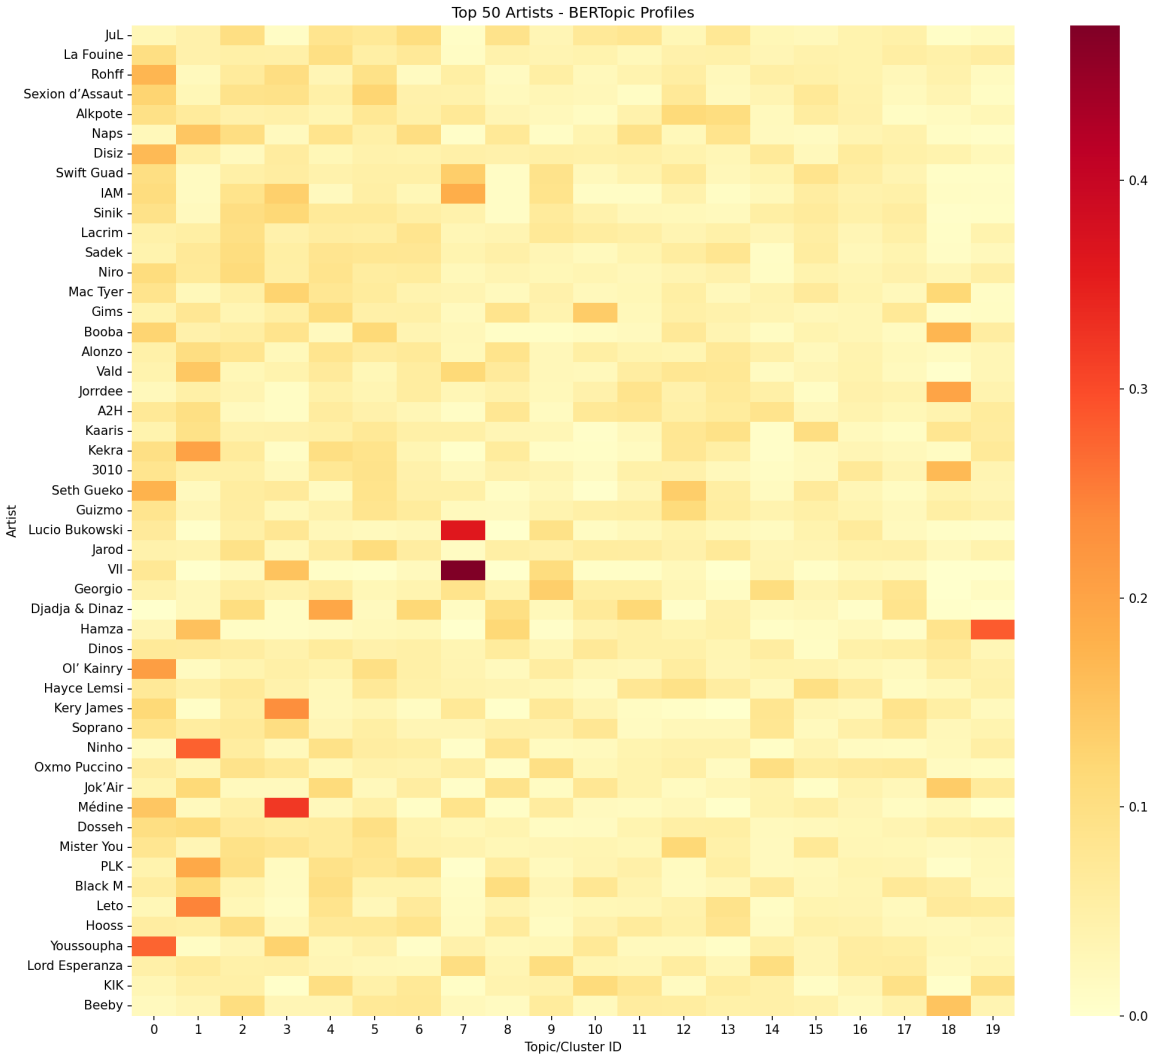

Figure 5: Artist-Topic Heatmap

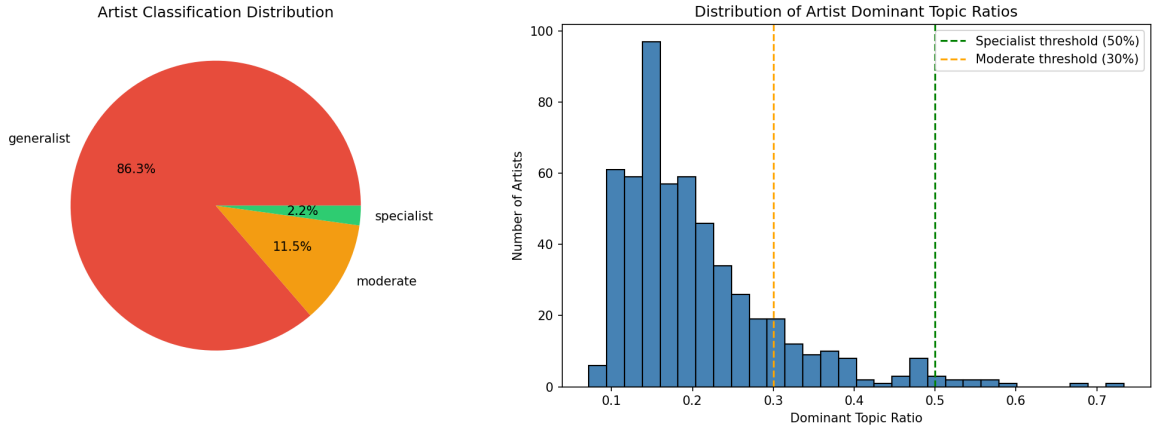

Figure 6: Artist Specialization

Dynamique Temporelle

Métrique	Valeur
Variance moyenne des topics	0.000655
JS annuel moyen	0.0803

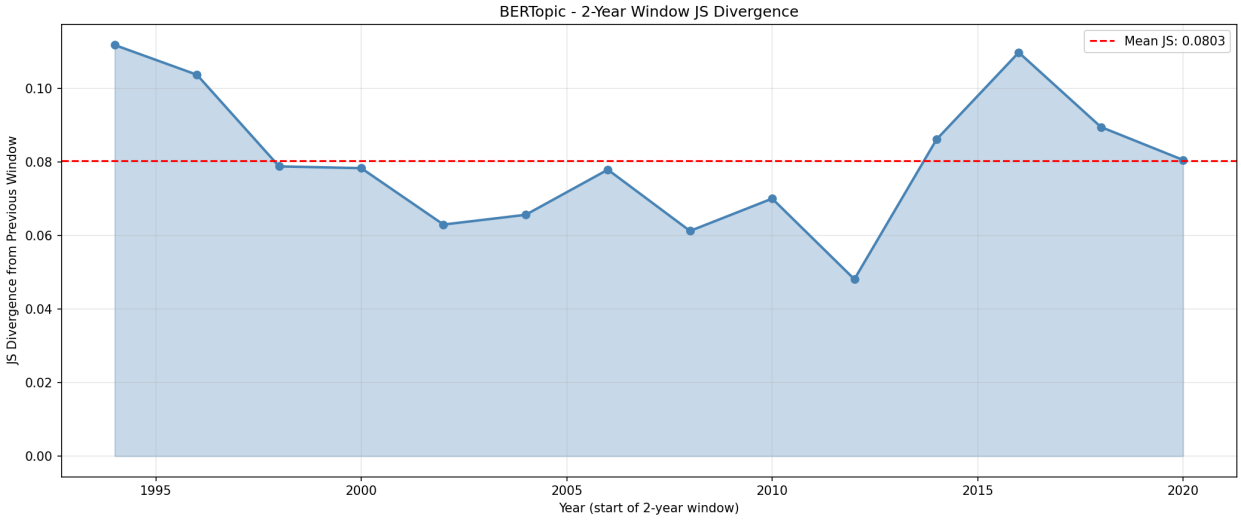

Figure 7: Annual JS

Divergence JS entre années consécutives.

Évolution des topics dans le temps.

Vue d'ensemble des Topics **Topic 0** — *Révolte et Identité dans le Rap*

- **c-TF-IDF:** de, le, les, est, la, pas, et, rap, un, on
- **KeyBERT (15 terms):** pas, ceux, ouais, rap, rappe, fait, comme, avec, monde, musique, vous, jamais, une, veux, que

Topic 1 — *Pression Sociale et Ambitions Contradictoires*

- **c-TF-IDF:** ouais, la, oh, est, hey, yeah, pas, dans, le, on
- **KeyBERT (15 terms):** ouais, oui, pas, vous, fait, comme, pour, vois, jamais, avec, vie, tu, veux, une, sur

Topic 2 — *Rébellion et Résilience dans la Rue*

- **c-TF-IDF:** les, la, le, de, on, pas, est, des, et, en
- **KeyBERT (15 terms):** pas, ouais, ceux, fait, vous, avec, comme, veux, monde, sur, jamais, vie, leur, une, pour

Topic 3 — *Résistances et Réalités Urbaines*

- **c-TF-IDF:** de, la, les, le, est, et, on, des, un, pas

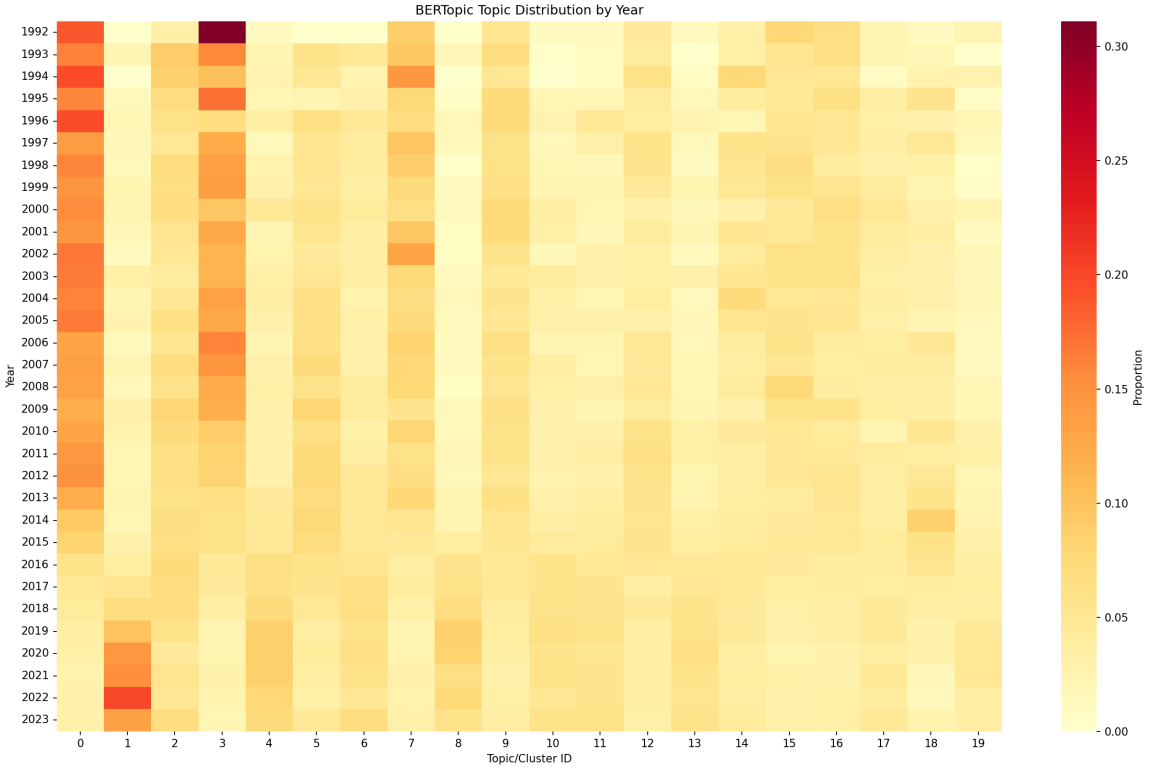

Figure 8: Year-Topic Heatmap

- **KeyBERT (15 terms):** pas, entre, leurs, fait, monde, ceux, avec, comme, une, sur, vous, veux, vie, france, leur

Topic 4 — *Interrogations Existentielles et Solitude*

- **c-TF-IDF:** la, est, pas, on, dans, le, qu, tu, je, les
- **KeyBERT (15 terms):** pourquoi, que, pas, fait, ouais, avec, monde, mais, vie, sur, quoi, qui, peux, oui, jamais

Topic 5 — *Réalité Crue et Résilience Urbaine*

- **c-TF-IDF:** les, la, le, de, est, pas, on, des, dans, et
- **KeyBERT (15 terms):** pas, ouais, vous, avec, fait, comme, monde, que, jamais, vie, une, sur, vois, veux, tu

Topic 6 — *Résilience et Lutte pour la Vie*

- **c-TF-IDF:** la, pas, le, les, de, est, on, je, ai, tu
- **KeyBERT (15 terms):** pas, ouais, vous, fait, peux, avec, comme, vie, passe, veux, pour, monde, tu, une, vois

Topic 7 — *Réflexions sur la Solitude et l'Injustice*

- **c-TF-IDF:** de, la, les, le, et, des, un, est, dans, en
- **KeyBERT (15 terms):** pas, fait, ceux, leurs, avec, entre, vie, comme, vous, monde, sur, une, veux, jour, homme

Topic 8 — *Amour, Perte et Résilience Urbaine*

- **c-TF-IDF:** oh, la, pas, est, moi, je, ai, tu, ma, on
- **KeyBERT (15 terms):** ouais, pas, cœur, oui, peux, vie, avec, fait, laisse, vois, sur, comme, veux, mais, pour

Topic 9 — *Desespoir et Lutte pour la Survivance*

- **c-TF-IDF:** de, la, le, les, est, et, je, que, un, on
- **KeyBERT (15 terms):** pas, cœur, fait, ceux, vie, comme, avec, monde, vous, sur, jour, une, pour, leur, veux

Topic 10 — *Amours Perdue et Solitude Urbaine*

- **c-TF-IDF:** je, tu, pas, moi, est, que, ai, de, la, toi
- **KeyBERT (15 terms):** vie, comme, pas, laisse, cœur, fait, voir, ouais, pourquoi, avec, mais, moi, pour, peux, jour

Topic 11 — *Chagrin et Résilience en Milieu Urbain*

- **c-TF-IDF:** la, pas, ai, est, je, de, tu, elle, le, qu
- **KeyBERT (15 terms):** pas, cœur, ouais, vie, vous, fait, peux, pour, avec, sur, tu, veux, mais, comme, jamais

Topic 12 — *Réalité du Ghetto et Résilience*

- **c-TF-IDF:** la, de, les, le, est, dans, un, des, pas, on
- **KeyBERT (15 terms):** pas, ouais, avec, fait, comme, vie, vous, sur, veux, que, tu, monde, jamais, une, chez

Topic 13 — *Rêves de Réussite et Réalité de la Rue*

- **c-TF-IDF:** la, pas, est, le, les, dans, suis, ai, on, de
- **KeyBERT (15 terms):** pas, vous, ouais, bon, peux, avec, vie, fait, comme, tu, veux, pour, que, connais, sur

Topic 14 — *Amour, Trahison et Désillusion*

- **c-TF-IDF:** elle, je, de, est, que, la, amour, pas, et, qu
- **KeyBERT (15 terms):** pas, fait, vie, comme, avec, cœur, amour, pour, mais, fais, vois, jamais, tu, sur, jour

… et 5 autres topics

Projection UMAP des embeddings colorés par topic.

2.2 LDA

Dossier du run: `results/LDA/run_20260224_094852_bigram_only`

Latent Dirichlet Allocation (Blei, Ng & Jordan, 2003) est un modèle génératif probabiliste représentant les documents comme mélanges de topics, où chaque topic est une distribution sur les mots. Cette implémentation utilise Gensim avec prétraitement n-gram.

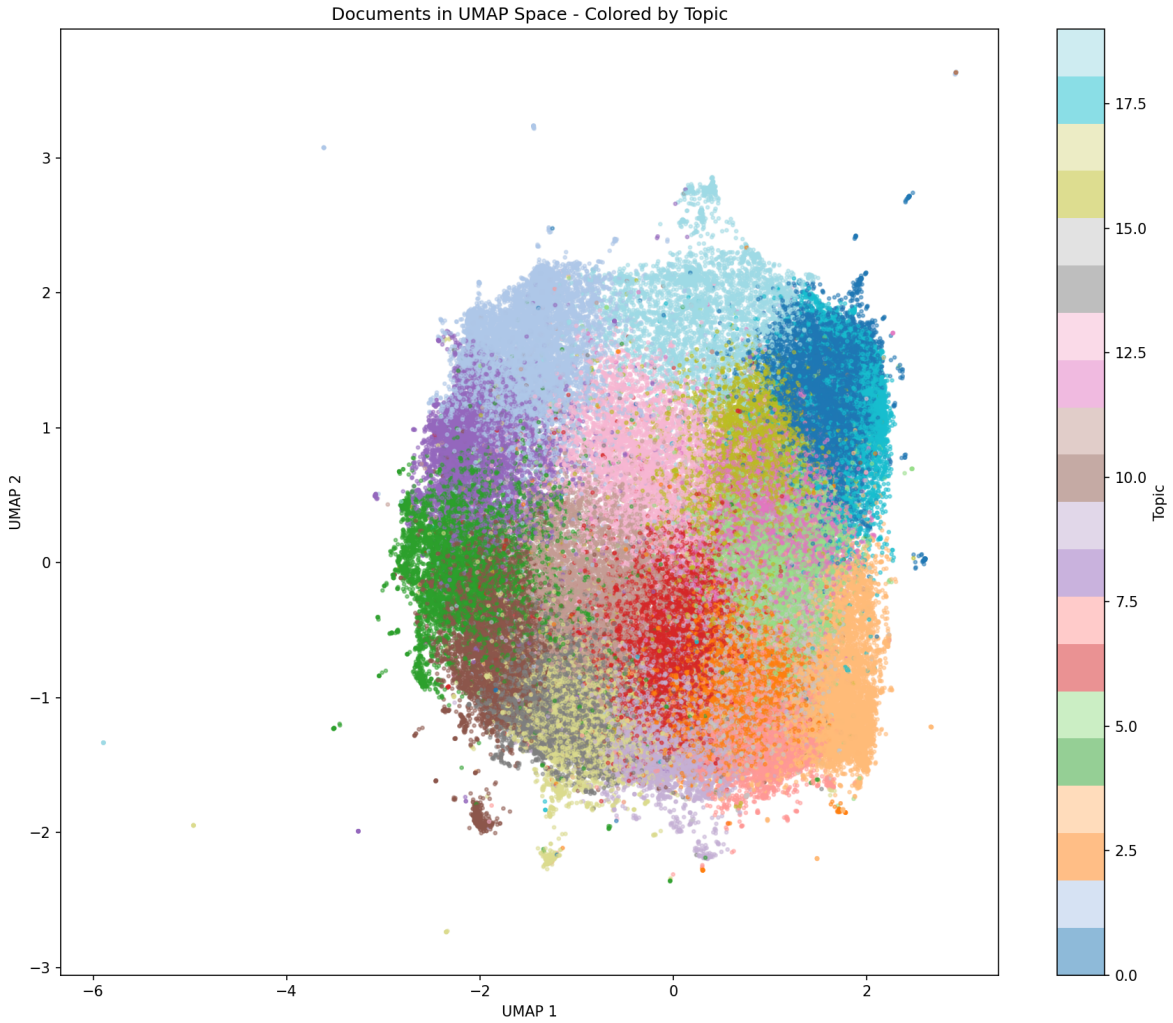

Figure 9: UMAP

Paramètres

Paramètre	Valeur
num_topics	20
alpha	symmetric
eta	auto
passes	15
iterations	400
min_word_len	2
min_doc_freq	5
max_doc_freq_ratio	0.3
use_ngrams	bigram_only
ngram_min_count	10
ngram_threshold	50
num_words_per_topic	30
keep_all_the_document	True

Scores de Cohérence

Métrique	Valeur	Interprétation
Cohérence C_v	0.5897	Bon
Cohérence UMass	-10.2532	Modéré

La cohérence C_v (Röder et al., 2015) mesure la cohérence sémantique des mots des topics.

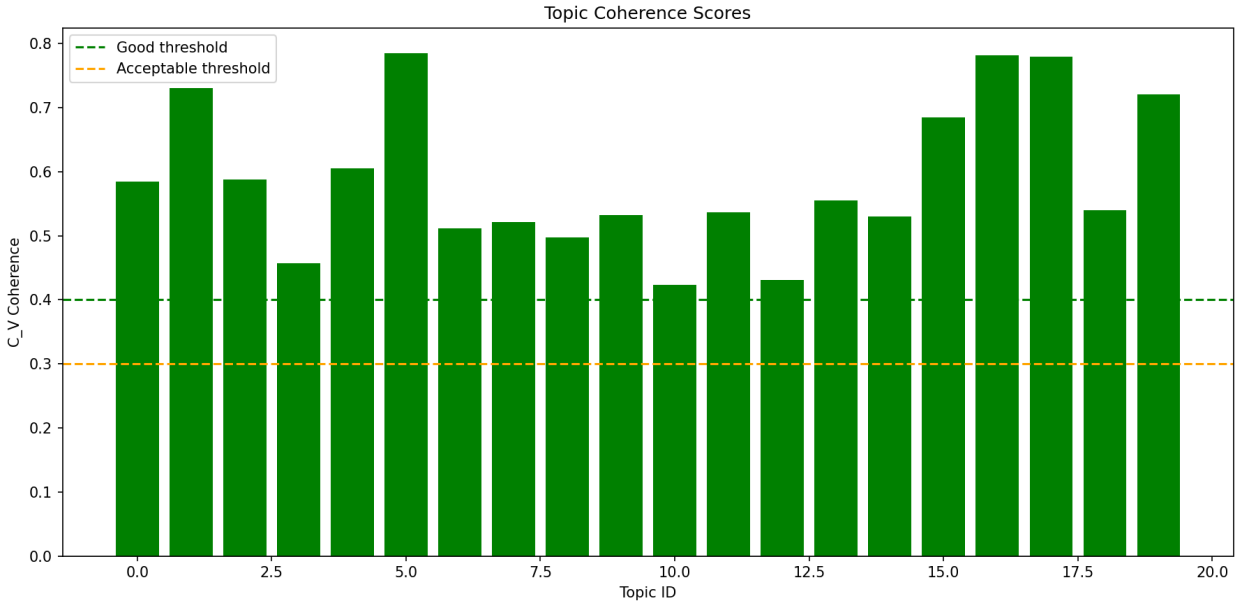

Figure 10: Coherence

Distribution des Topics

Métrique	Valeur	Interprétation
Nombre de topics	20	-
Ratio d'imbalance	17.06	Très déséquilibré
Entropie de distribution	0.887	Bien distribué

Définitions des métriques :

- **Ratio d'imbalance** = max(compte_topic) / min(compte_topic). Mesure l'inégalité des tailles de topics.
- **Entropie de distribution** (normalisée) = -Σ(p_i × log(p_i)) / log(n_topics). Intervalle [0,1] : 1 = uniforme.

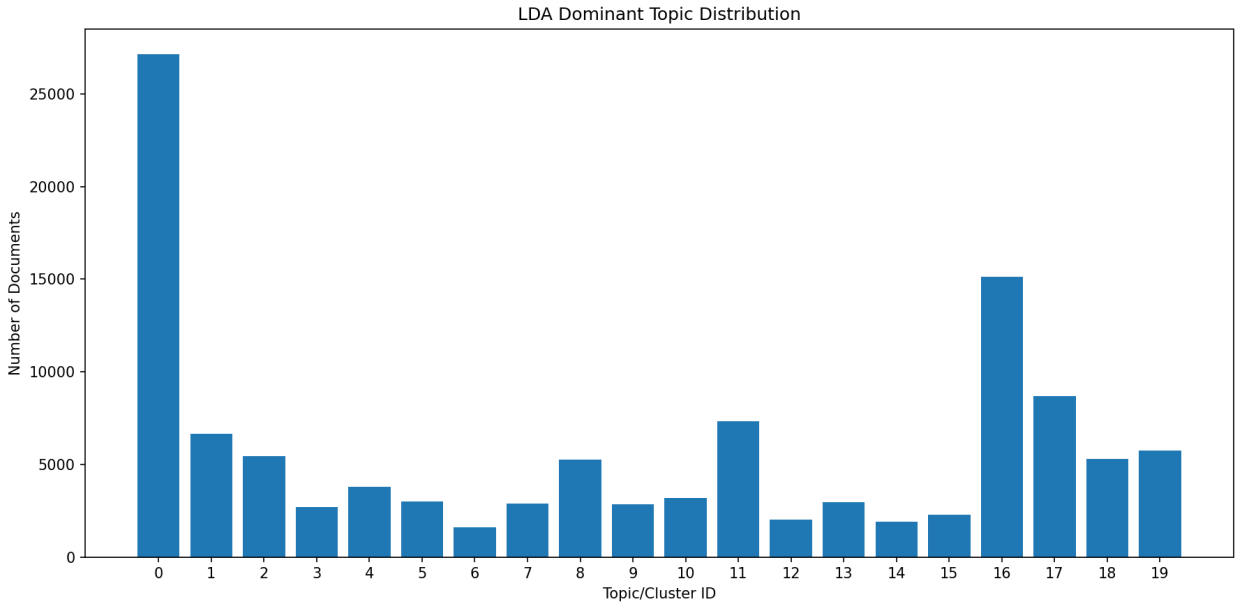

Figure 11: Topic Distribution

Distribution des documents par topic.

Séparation des Artistes

Métrique	Valeur	Description
% Spécialistes	0.5%	Artistes avec >50% dans un topic
% Modérés	22.4%	Artistes avec 25-50% dans le topic dominant
% Généralistes	77.0%	Artistes répartis sur plusieurs topics
Indice de spécialisation	0.186	Concentration moyenne
Divergence JS	0.140	Divergence des profils d'artistes

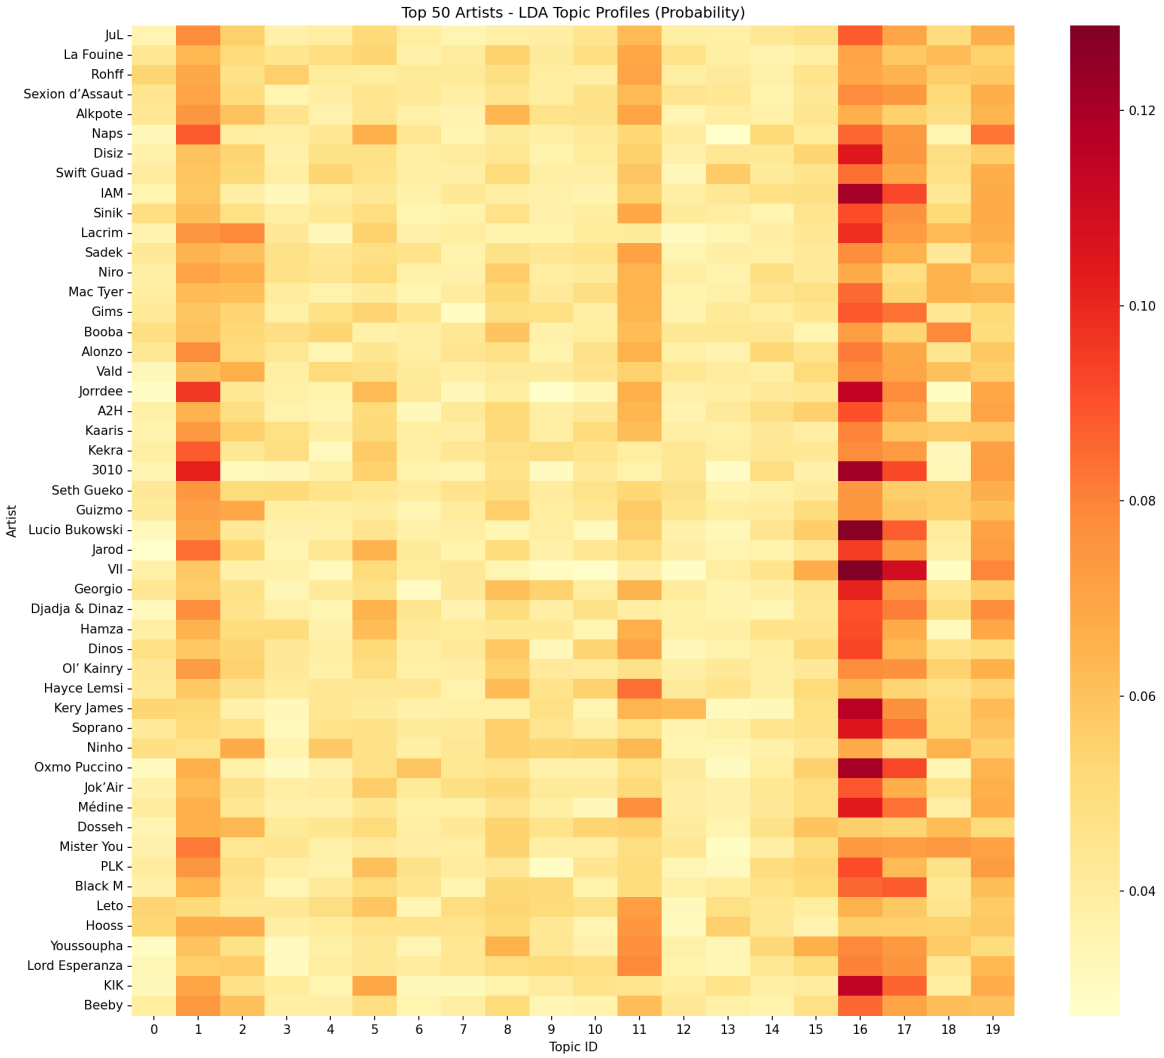

Figure 12: Artist-Topic Heatmap

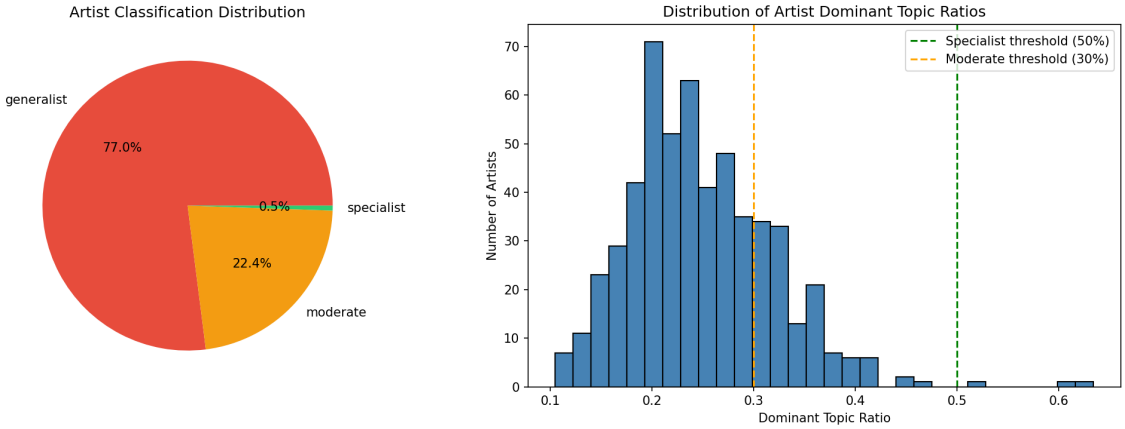

Figure 13: Artist Specialization

Heatmap de distribution des artistes par topic.

Profils de spécialisation des artistes.

Dynamique Temporelle

Métrique	Valeur
Variance moyenne des topics	0.000032
JS annuel moyen	0.0272

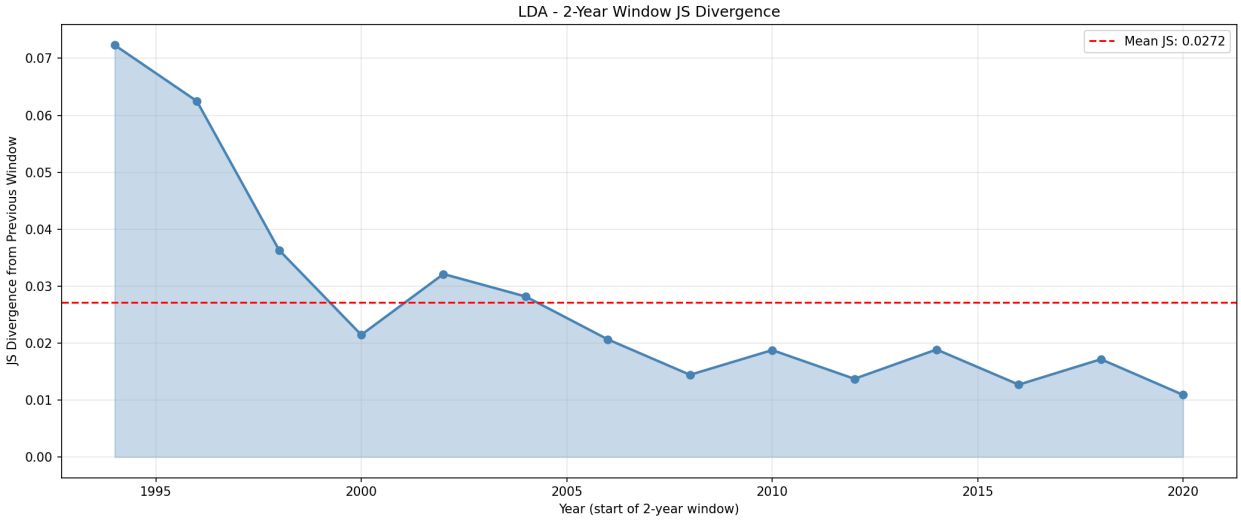

Figure 14: Annual JS

Divergence JS entre années consécutives.

Évolution des topics dans le temps.

Vue d'ensemble des Topics

Topic	Mots clés
0	coeur, bye_bye, savais, comptes, yeux_rouges, madame, voudrais, full, douce_france, satan
1	d'la, rue, merde, putain, parle, gars, connais, j'vais, négro, j'veux
2	fils_pute, j'm'en_fous, j'en_marre, chaud_chaud, fils_putes, yeux_fermés, bord_mer, gucci, i'm, canon_scié
3	xxx, bat_couilles, semblant, quatre, briller, air_max, fumé, tient, grammes, taff
4	j'y_pense, ailleurs, pense_qu'à, d'ma_mère, aurait_pu, rend_fou, prie, j'vous, po_po, sac_dos

Topic	Mots clés
5	m’a, vu, j’veux, j’étais, j’me, j’vais, j’peux, c’était, j’avais, pris
6	belle, sale, j’connais, danser, étais, vies, petite, bonne, meilleur, dieu_merci
7	comment, ouh, ciel, hip_hop, j’te_jure, étoiles, souvenirs, nulle_part, barre, montre
8	deux_trois, d’en_bas, ferme_yeux, jusqu’au_bout, tirer, l’impression_d’être, m’a_rendu, roue_tourne, j’rentre, s’il_plait
9	j’pense, m’as, bon, dix_ans, donné, t’aime, voulais, trouvé, rempli, n’a_changé
10	bang_bang, p’tit, j’me_rappelle, tess, beuh, bienvenue, dalle, solo, équipe, paw_paw
11	j’me_sens, paroles_rédigées, j’aurais_pu, expliquées_communauté, qu’j’ai, terrain, rapgenius_france, disque_d’or, s’il_plaît, doigt
12	demain, zone, ferme_gueule, mama, fera, jours, marseille, ira, bloc, obligé
13	vas, t’inquiète, tourne_rond, années_passent, qu’tu_sois, souffrir, faits_divers, nord_sud, l’être_humain, compte_banque
14	j’aime, bébé, noir, lune, rentre, j’prends, aura, qu’j’suis, paye, danse

… et 5 autres topics

Projection PCA des distributions topic-mot.

2.3 IRAMUTEQ

Dossier du run: `results/IRAMUTEQ/evaluation_20260126_124001`

IRAMUTEQ implémente la méthode ALCESTE de Reinert (Reinert, 1983), qui effectue une classification hiérarchique descendante sur les segments de texte, identifiant les mondes lexicaux.

Paramètres

Paramètre	Valeur
method	`IRAMUTEQ`
n_classes	`20`
n_documents	`115805`
min_docs_per_artist	`10`
top_artists_per_topic	`20`

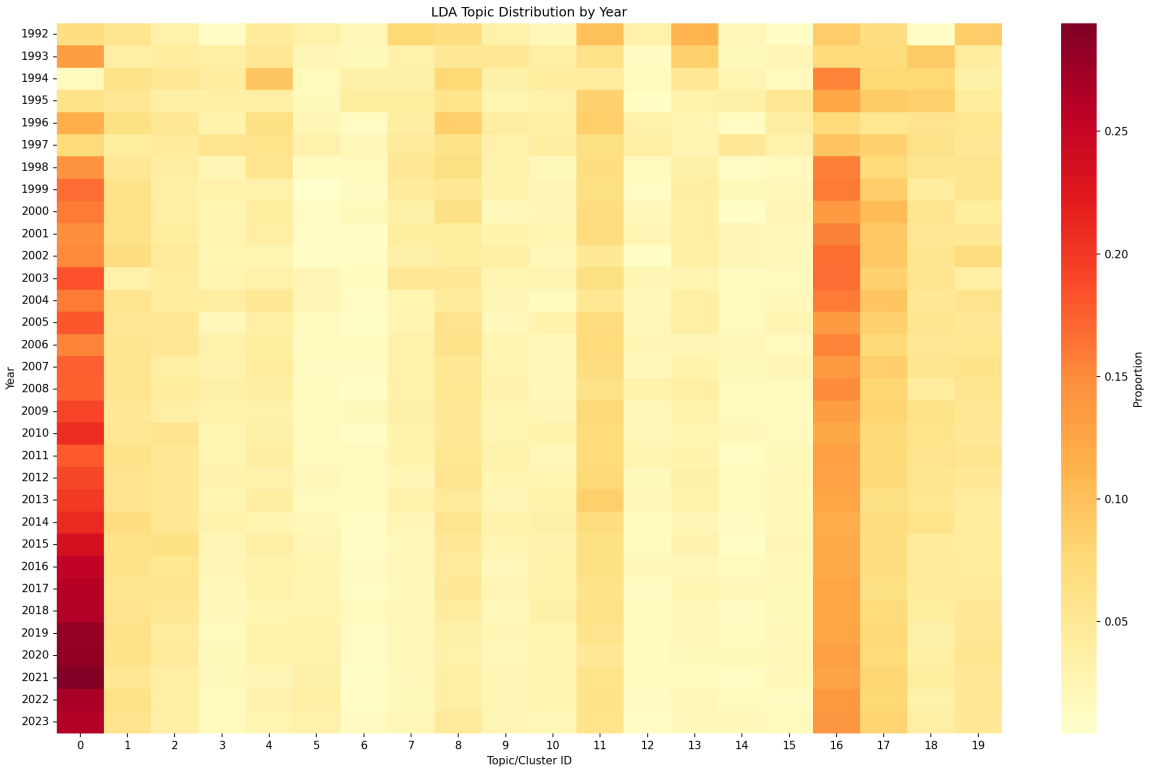

Figure 15: Year-Topic Heatmap

Distribution des Topics

Métrique	Valeur	Interprétation
Nombre de topics	20	-
Ratio d'imbalance	31.70	Très déséquilibré
Entropie de distribution	2.709	Quasi uniforme

Définitions des métriques :

- **Ratio d'imbalance** = max(compte_topic) / min(compte_topic). Mesure l'inégalité des tailles de topics.
- **Entropie de distribution** (normalisée) = -Σ(p_i × log(p_i)) / log(n_topics). Intervalle [0,1] : 1 = uniforme.

Distribution des documents par topic.

Séparation des Artistes

Métrique	Valeur	Description
% Spécialistes	12.2%	Artistes avec >50% dans un topic
% Modérés	44.3%	Artistes avec 25-50% dans le topic dominant
% Généralistes	43.4%	Artistes répartis sur plusieurs topics
Indice de spécialisation	0.364	Concentration moyenne
Divergence JS	0.541	Divergence des profils d'artistes

Heatmap de distribution des artistes par topic.

Topic	Mots clés
2	chen, ekip, ldo, zuukou, etho, goddamn, nrm, digi, mms, lin
3	jul, marseille, gadji, moto, poto, fumette, bdh, zone, dégun, miss
4	hey, brr, yah, gucci, grr, gang, bébé, mmh, woh, fendi
5	luni, slimes, geeked, shawty, sacki, voidd, drip, majdon, ola, slime
6	sexion, wati, assaut, 9ème, gims, jeryzoos, akhi, maska, llefa, 3ème
7	bitch, négro, flow, meuf, club, weed, flex, boy, yo, dj
8	france, peuple, pays, politique, afrique, communauté, rédiger, justice, état, système
9	cli, ients, binks, détailler, midi, minuit, visser, gue, terrain, pe
10	mic, rime, rap, style, mc, hip_hop, rimer, beat, micro, texte
11	art, swift, acide, artère, guad, tekk, carcasse, delleck, corps, nikkfurie
12	chose, impression, penser, fois, temps, gens, question, moment, envie, vraiment
13	amour, aimer, sentiment, mentir, couple, amoureux, relation, femme, coeur, défaut
14	2mz, qlf, sourou, igd, pnl, adios, amigo, benab, igo, rio
15	billet, violet, monnaie, vert, liasse, euro, poche, payer, charbonner, bleu

… et 5 autres topics

---

3. Analyse Comparative

3.1 Q1 : Les modèles capturent-ils la même structure ?

Question de recherche : Les différentes approches découvrent-elles des structures similaires ?

Contexte Méthodologique Nous utilisons trois métriques d'accord de clustering :

Adjusted Rand Index (ARI) — Hubert, L., & Arabie, P. (1985)

L'indice de Rand ajusté mesure la similarité entre deux clusterings, corrigé par le hasard. Il calcule le nombre d'accords de paires (toutes deux dans le même cluster ou toutes deux dans des clusters différents), normalisé par la valeur attendue sous un

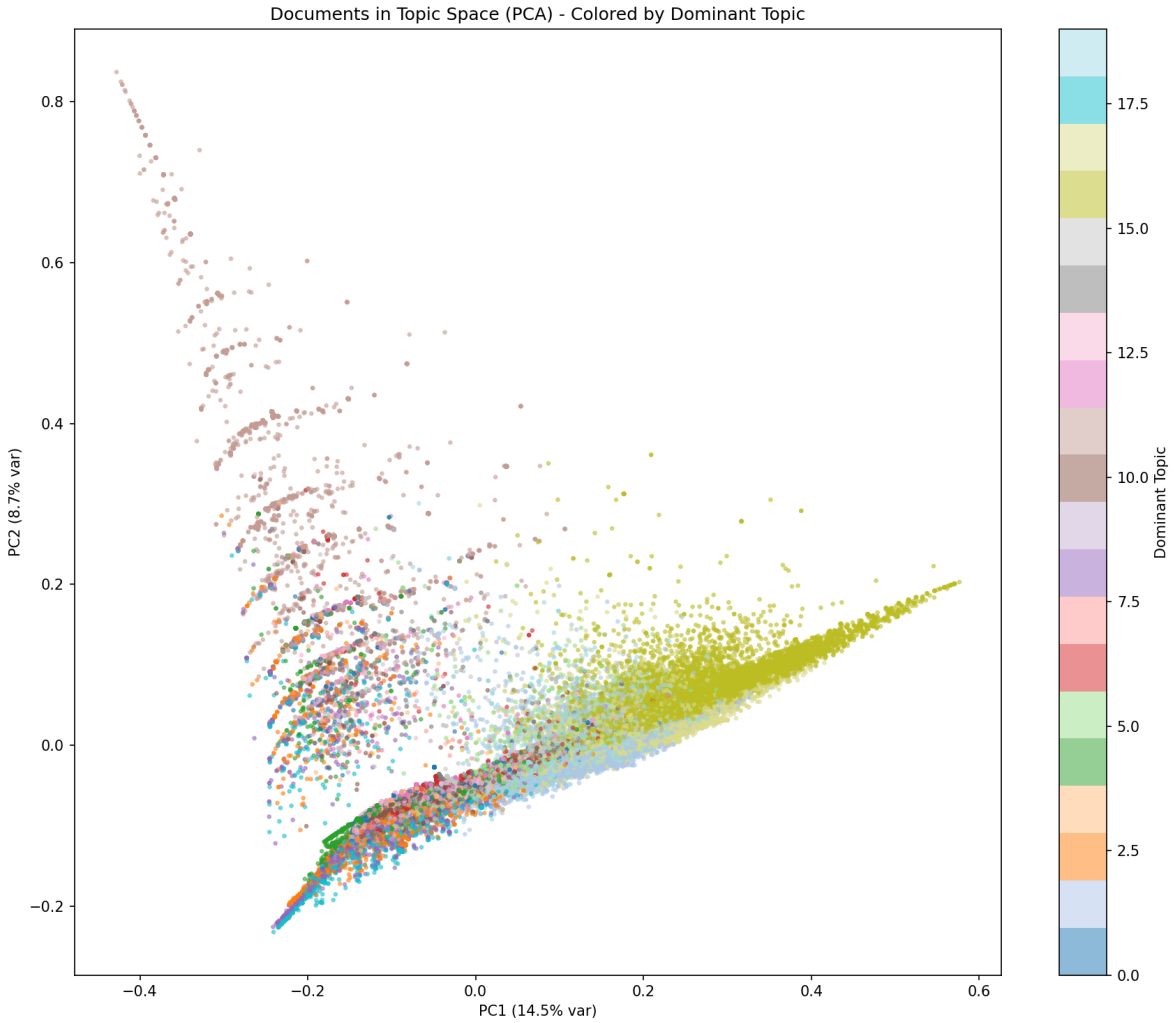

Figure 16: PCA

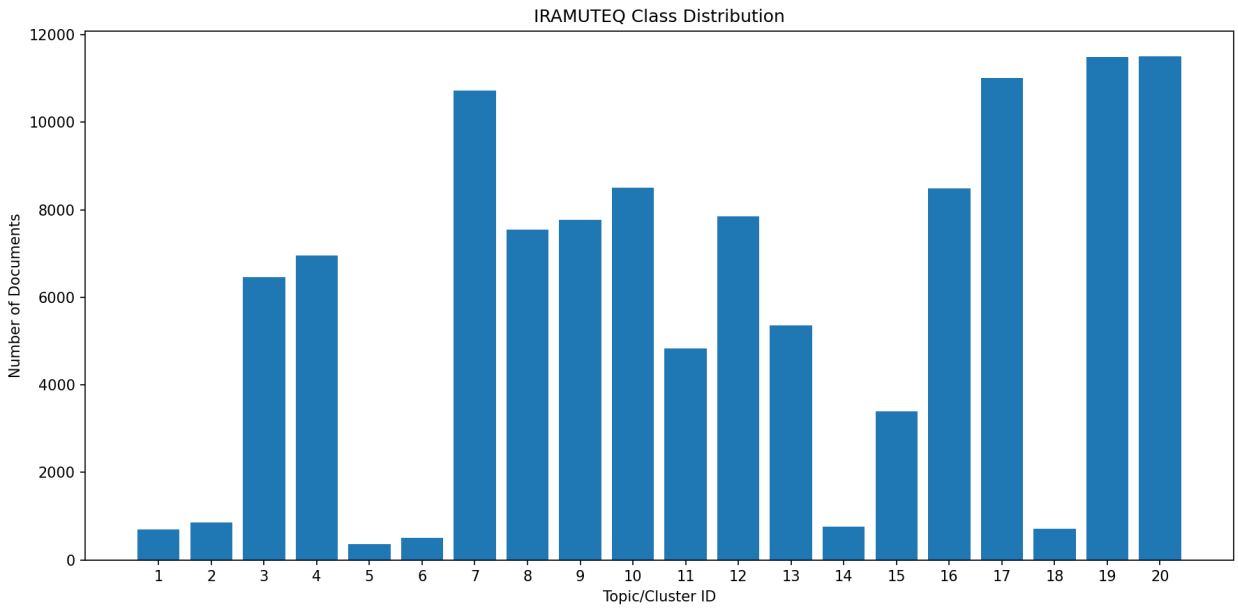

Figure 17: Topic Distribution

modèle aléatoire. ARI = (RI - RI_attendu) / (RI_max - RI_attendu). Intervalle : [-1, 1], où 1 = accord parfait, 0 = aléatoire, <0 = inférieur au hasard.

Normalized Mutual Information (NMI) — Strehl, A., & Ghosh, J. (2002)

La NMI mesure la dépendance mutuelle entre deux clusterings en utilisant la théorie de l'information. Elle quantifie dans quelle mesure la connaissance d'un clustering réduit l'incertitude sur l'autre. NMI = 2 × I(X;Y) / (H(X) + H(Y)), où I est l'information mutuelle et H l'entropie. Intervalle : [0, 1], où 1 = clusterings identiques, 0 = indépendants.

Résultats

Paire	ARI	NMI	Interprétation
bertopic_vs_lda	0.0076	0.0150	Quasi aléatoire
bertopic_vs_iramuteq	0.0442	0.1024	Accord faible
lda_vs_iramuteq	0.0049	0.0151	Quasi aléatoire

Observations clés :

1. **Meilleur accord :** bertopic_vs_iramuteq (NMI = 0.1024)
2. **Accord le plus faible :** bertopic_vs_lda (NMI = 0.0150)
3. **Pattern général :** Les scores d'accord relativement faibles (NMI < 0.5) suggèrent que chaque modèle capture des aspects distincts :

- BERTopic : similarité sémantique (sens)
- LDA : co-occurrences de mots (distribution)

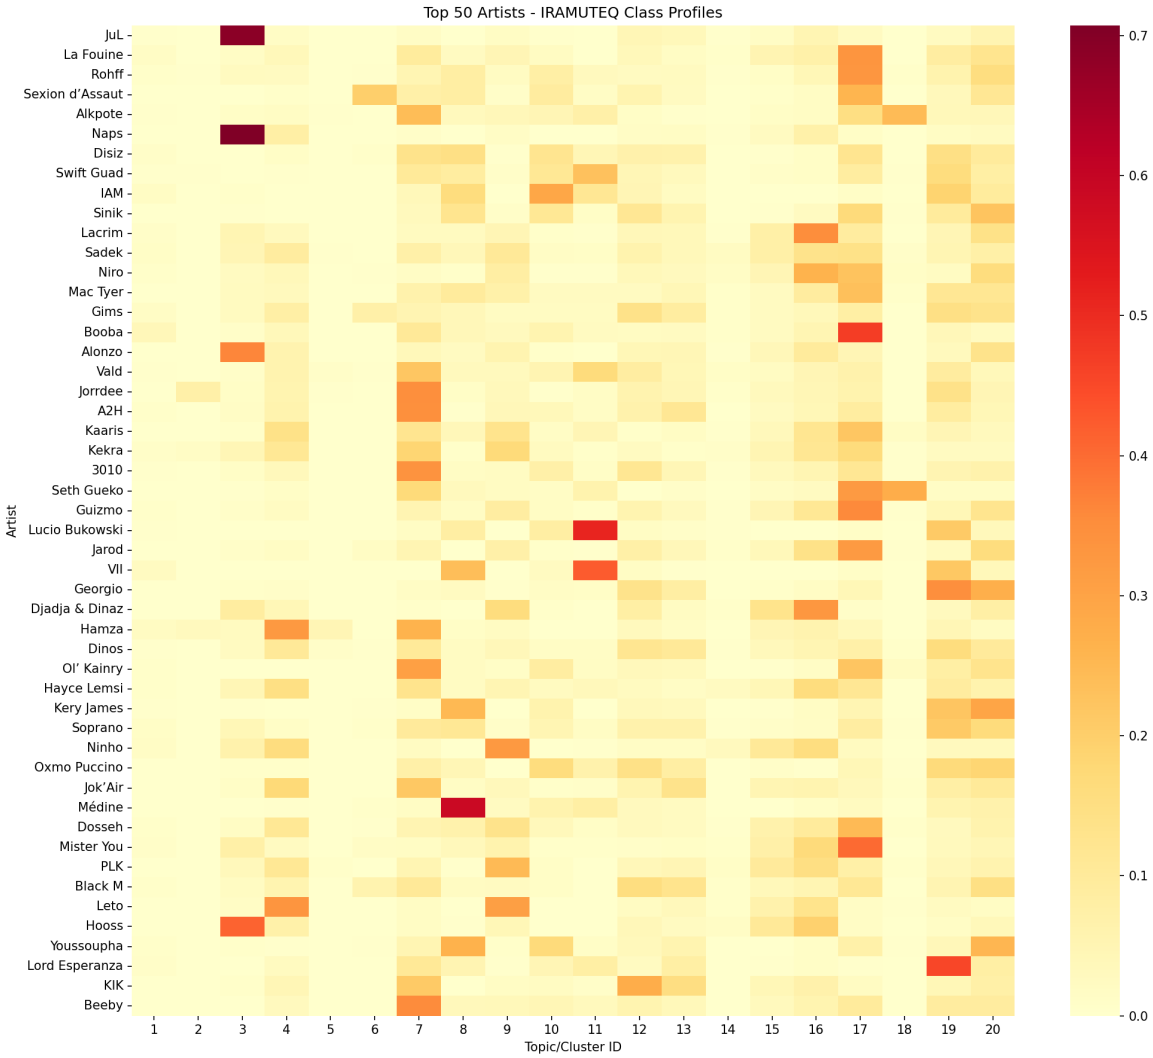

Figure 18: Artist-Topic Heatmap

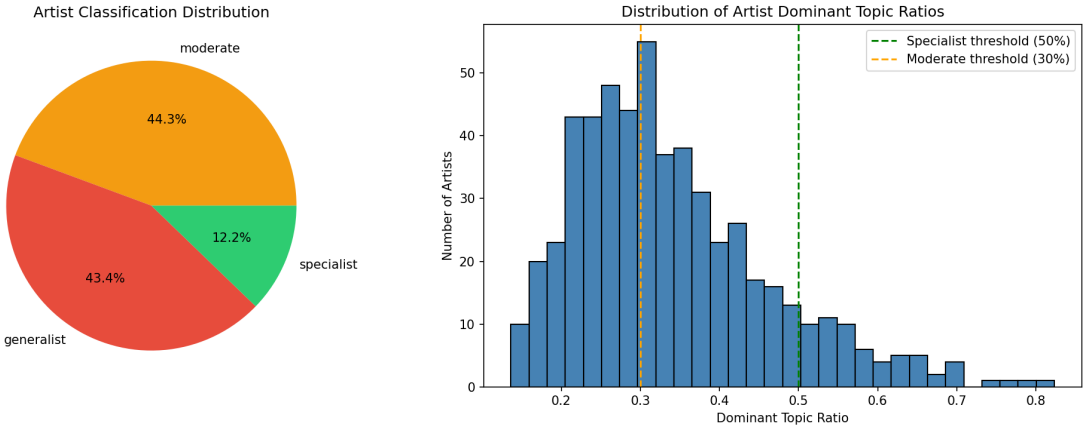

Figure 19: Artist Specialization

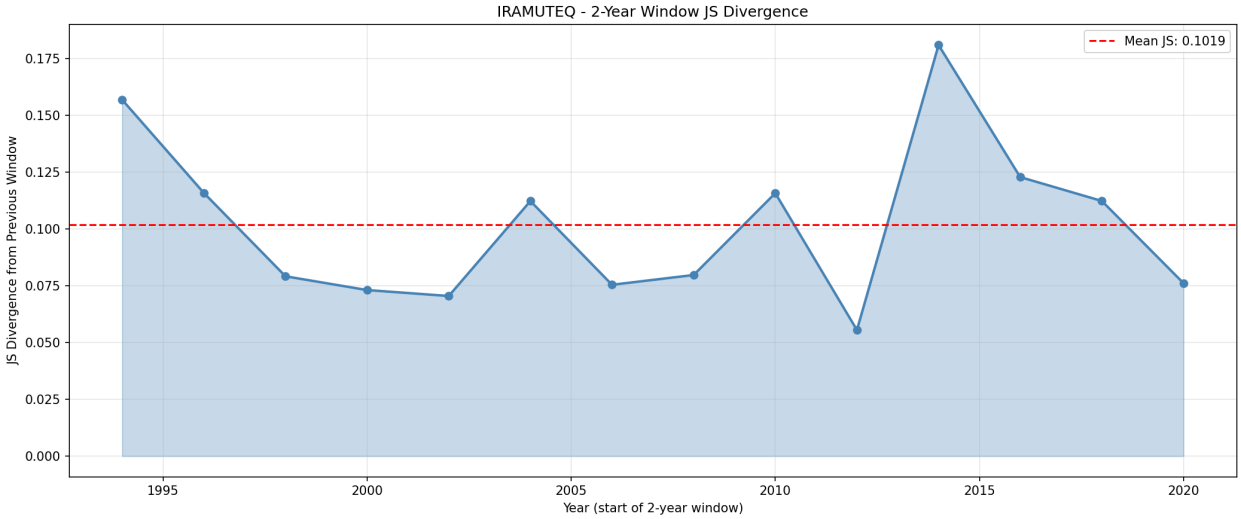

Figure 20: Annual JS

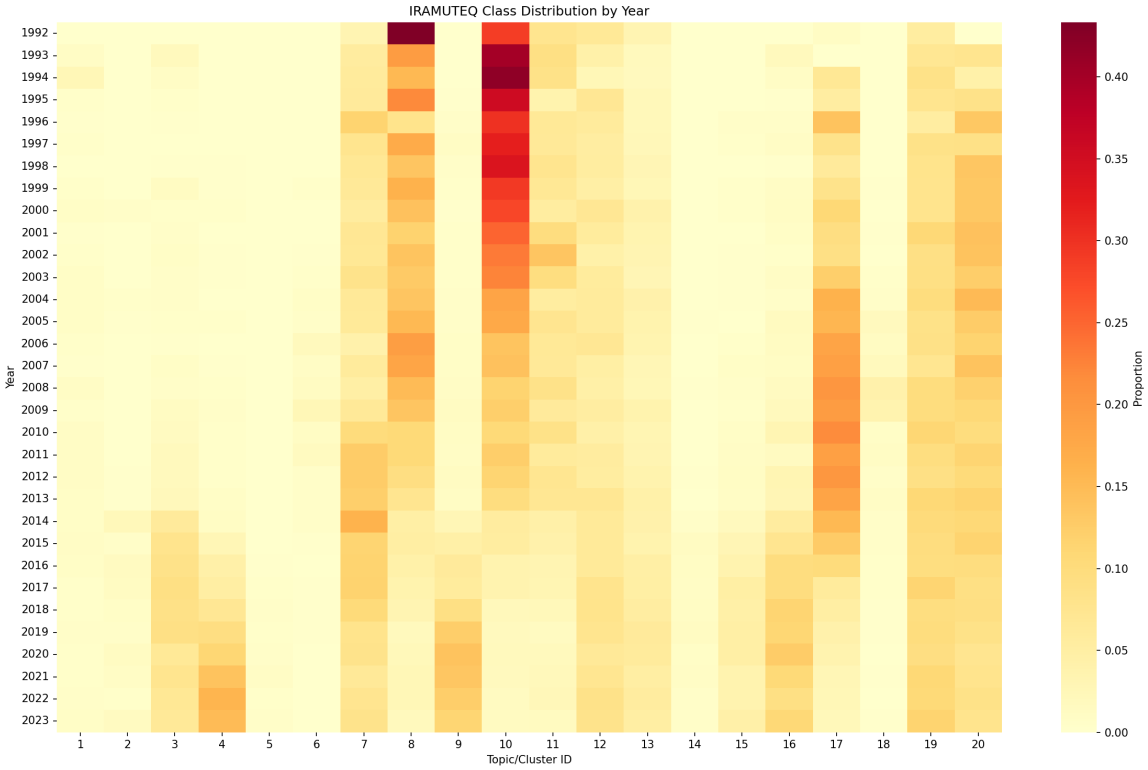

Figure 21: Year-Topic Heatmap

- IRAMUTEQ : classification lexicale (vocabulaire)

3.2 Q2 : Les modèles séparent-ils les artistes ?

Question de recherche : Les topics capturent-ils des signatures stylistiques propres aux artistes ?

Contexte Méthodologique **V de Cramér** — Cramér, H. (1946)

Le V de Cramér mesure la force d'association entre deux variables catégorielles. Il est dérivé de la statistique du chi-deux : $V = \sqrt{(\chi^2 / (n \times \min(k-1, r-1)))}$, où k et r sont le nombre de catégories. V normalise le chi-deux par la taille de l'échantillon et la dimensionnalité, permettant la comparaison entre tables de tailles différentes. Intervalle : [0, 1], où 0 = aucune association, 1 = association parfaite.

Résultats

Modèle	V de Cramér	Interprétation
BERTOPIC	0.2079	Association modérée
LDA	0.1143	Association faible
IRAMUTEQ	0.3854	Association forte

Observations clés :

1. **Séparation la plus forte :** IRAMUTEQ (V = 0.3854)
2. **Spécialistes :** La proportion varie selon les modèles.
3. **Généralistes :** Artistes répartis sur plusieurs topics = thèmes divers.

3.3 Q3 : Les modèles capturent-ils l'évolution temporelle ?

Question de recherche : Les distributions de topics changent-elles dans le temps ?

Contexte Méthodologique **Variance Temporelle** : Mesure la fluctuation des topics au fil du temps.

Résultats

Modèle	Variance Temporelle	Topic le plus variable	Variance max	Interprétation
BERTOPIC	0.000677	3	0.003566	Stable
LDA	0.000034	16	0.000094	Stable
IRAMUTEQ	0.001917	9	0.015929	Dynamique modérée

Observations clés :

1. **Le plus dynamique :** IRAMUTEQ montre la variance la plus élevée.
2. **Transitions majeures :** Une divergence JS élevée entre décennies indique des changements.
3. **Topics stables vs évolutifs :** Faible variance = thèmes pérennes, haute variance = tendances.

3.4 Q4 : Quelle est la distinctivité lexicale des topics ?

Question de recherche : Les topics représentent-ils des vocabulaires distincts ?

Contexte Méthodologique **Distance de Jaccard** : Mesure la distinctivité du vocabulaire entre topics.

Distinctivité : Distance de Jaccard moyenne entre vocabulaires de topics.

Résultats

Modèle	Distance de Jaccard Moyenne	Interprétation
BERTOPIC	0.5062	Chevauchement modéré
LDA	0.9977	Topics très distincts
IRAMUTEQ	0.9964	Topics très distincts

Observations clés :

1. **LDA et IRAMUTEQ** montrent une haute distinctivité (>0.9).
2. **BERTopic** peut montrer une distinctivité plus faible (embeddings sémantiques).

Chevauchement Lexical Inter-Modèles (Vocabulaire Complet) Pour évaluer le recouvrement lexical entre les topics correspondants de BERTopic et LDA, nous calculons l'indice de Jaccard sur le **vocabulaire complet** des documents assignés à chaque topic (et non sur les seuls mots représentatifs extraits par c-TF-IDF ou probabilité). Nous faisons varier le seuil de fréquence minimale pour distinguer le vocabulaire fonctionnel partagé (seuil bas, Jaccard élevé) du vocabulaire thématique spécifique (seuil élevé, Jaccard plus faible). Un Jaccard décroissant avec le seuil indique que les modèles divergent sur les termes spécialisés tout en partageant le socle lexical commun.

Seuil min. freq.	Jaccard moyen	Paires
1	0.3639	20
5	0.3904	20
20	0.3391	20

3.5 Q5 : Quelle est l'homogénéité lexicale des topics ?

Question de recherche : Les documents d'un même topic sont-ils lexicalement similaires ?

Des distances intra-topic plus faibles indiquent des clusters plus cohérents.

Contexte Méthodologique Nous calculons les distances par paires entre documents du même topic. Deux métriques complémentaires :

Distance	Ce qu'elle capture	Justification scientifique
Jensen-Shannon	Divergence distributionnelle	Largement utilisée en NLP. Fondée sur la théorie de l'information. Bornée [0,1].
Labbé	Homogénéité lexicale	Standard JADT pour la stylométrie française.

Jensen-Shannon — Lin, J. (1991)

La distance JS est la racine carrée de la divergence JS, une mesure symétrique de similarité entre distributions de probabilité. scipy.spatial.distance.jensenshannon() retourne directement cette valeur de distance. La distance JS est une métrique propre satisfaisant l'inégalité triangulaire. Intervalle : [0, 1], où 0 = distributions identiques, 1 = maximalement différentes.

Labbé — Labbé, D., & Labbé, C. (2001)

La distance de Labbé mesure la similarité lexicale entre deux textes, implémentée selon l'algorithme original d'IRAMUTEQ. Elle gère explicitement l'asymétrie de longueur entre textes : 1) Identifier le texte plus petit (N_small) et plus grand (N_large) 2) Normaliser les comptages du texte plus grand : n'_i = n_i × U où U = N_small/N_large 3) Calculer la somme des différences absolues sur les comptages normalisés 4) Normaliser : D = Σ|n_small - n'_large| / (N_small + Σ(n' où n'≥1)) Cette métrique est le standard en stylométrie française et dans la communauté JADT pour l'attribution d'auteur. Intervalle : [0, 1], où 0 = vocabulaires identiques, 1 = aucun chevauchement.

Résultats Distance Jensen-Shannon (Distributionnelle)

Modèle	Distance Moyenne	Écart-type	Topics	Interprétation
BERTOPIC	0.8201	0.0021	20	Très hétérogène
LDA	0.8203	0.0020	20	Très hétérogène
IRAMUTEQ	0.8185	0.0069	20	Très hétérogène

Distance de Labbé (Lexicale)

Modèle	Distance Moyenne	Écart-type	Topics	Interprétation
BERTOPIC	0.9771	0.0040	20	Très hétérogène
LDA	0.9782	0.0042	20	Très hétérogène
IRAMUTEQ	0.9748	0.0131	20	Très hétérogène

Observations clés :

1. **Meilleure homogénéité distributionnelle (JS) :** IRAMUTEQ montre la distance moyenne la plus faible (0.8185).
2. **Meilleure homogénéité lexicale (Labbé) :** IRAMUTEQ montre la distance moyenne la plus faible (0.9748).
3. **Complémentarité :** JS capture la similarité distributionnelle, Labbé le chevauchement lexical absolu.

Analyse par Topic Top 5 topics les plus et les moins homogènes (distance JS) :

BERTOPIC

Topics les plus homogènes :

Topic	Distance JS Moyenne	Documents
14	0.8159	4959
0	0.8178	9049
10	0.8178	5437
17	0.8182	4736
9	0.8183	5470

Topics les moins homogènes :

Topic	Distance JS Moyenne	Documents
7	0.8215	5585
15	0.8216	4791
3	0.8216	7098
8	0.8230	5534
4	0.8250	6799

LDA

Topics les plus homogènes :

Topic	Distance JS Moyenne	Documents
2	0.8165	5432
18	0.8180	5296

Topic	Distance JS Moyenne	Documents
11	0.8181	7323
13	0.8186	2954
8	0.8187	5250

Topics les moins homogènes :

Topic	Distance JS Moyenne	Documents
15	0.8221	2276
1	0.8227	6637
5	0.8228	2988
19	0.8235	5748
0	0.8239	27139

IRAMUTEQ

Topics les plus homogènes :

Topic	Distance JS Moyenne	Documents
1	0.7899	704
12	0.8160	7853
13	0.8160	5362
20	0.8165	11508
5	0.8172	363

Topics les moins homogènes :

Topic	Distance JS Moyenne	Documents
18	0.8219	709
8	0.8222	7549
7	0.8224	10727
4	0.8228	6950
11	0.8234	4837

Voir Annexe B pour une explication des métriques de distance.

Analyse par Configuration de Distance Nous calculons les distances selon 4 configurations complémentaires pour évaluer différents aspects de la qualité des topics :

Configuration	Ce qu'elle mesure	Guide d'interprétation
Intra-topic (paires)	Homogénéité	Plus bas = meilleur
Inter-topic (paires)	Séparation	Plus haut = meilleur
Intra-topic (agrégé) (n=20)	Homogénéité	Plus bas = meilleur
Inter-topic (agrégé) (n=20)	Séparation	Plus haut = meilleur

Note : L'agrégation de 20 couplets crée des unités textuelles plus comparables pour la distance de Labbé, qui est sensible à la longueur des textes.

Intra-topic (paires)

*Distances entre paires de documents du même topic. Mesure l'**homogénéité interne** : des distances faibles indiquent des topics cohérents.*

Modèle	JS	Labbé
BERTOPIC	0.8201	0.9771
LDA	0.8203	0.9782
IRAMUTEQ	0.8185	0.9748

Inter-topic (paires)

*Distances entre documents du topic et documents hors du topic. Mesure la **séparation** : des distances élevées indiquent des topics bien distincts.*

Modèle	JS	Labbé
BERTOPIC	0.8220	0.9813
LDA	0.8216	0.9806
IRAMUTEQ	0.8229	0.9832

Intra-topic (agrégé) (n=20)

Comme intra-paires, mais en agrégeant n couplets ensemble. Réduit la sensibilité de Labbé aux différences de longueur.

Modèle	JS	Labbé
BERTOPIC	0.7111	0.7658
LDA	0.7121	0.7659
IRAMUTEQ	0.7022	0.7543

Inter-topic (agrégé) (n=20)

Comme inter-paires, mais avec documents agrégés. Plus robuste pour les comparaisons de séparation.

Modèle	JS	Labbé
BERTOPIC	0.7261	0.7943
LDA	0.7211	0.7840
IRAMUTEQ	0.7345	0.8132

Synthèse des 4 configurations :

- **Meilleure homogénéité (JS):** IRAMUTEQ (0.8185)
- **Meilleure homogénéité (Labbé):** IRAMUTEQ (0.9748)
- **Meilleure séparation (JS):** IRAMUTEQ (0.8229)
- **Meilleure séparation (Labbé):** IRAMUTEQ (0.9832)

Stabilisation de la distance de Labbé par agrégation Cette analyse montre comment la distance de Labbé évolue en fonction du nombre de couplets agrégés. La distance de Labbé étant sensible à la longueur des textes, l'agrégation de plusieurs couplets produit des unités textuelles plus comparables et des distances plus stables.

Plage d'agrégation : de 8 à 72 documents (>500 mots/unité, ≥5 unités/topic), 5 points. Taille minimale de topic (tous modèles) : 363 documents.

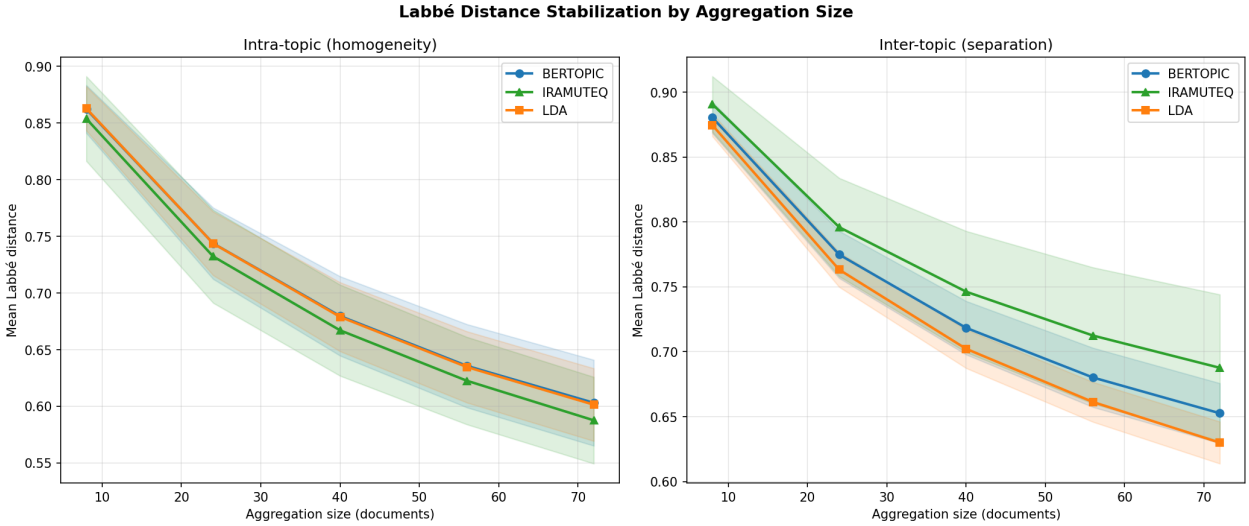

Figure 22: Aggregation Curve

Évolution de la distance de Labbé intra-topic (gauche) et inter-topic (droite) en fonction de la taille d'agrégation.

Classement de la séparation inter-topic Pour chaque modèle, les topics sont classés par leur distance inter-topic moyenne (un-contre-reste). Des distances plus élevées indiquent des topics lexicalement plus distincts du reste du corpus.

Classement des topics par séparation inter-topic (BERTOPIC).

Topics les plus distincts :

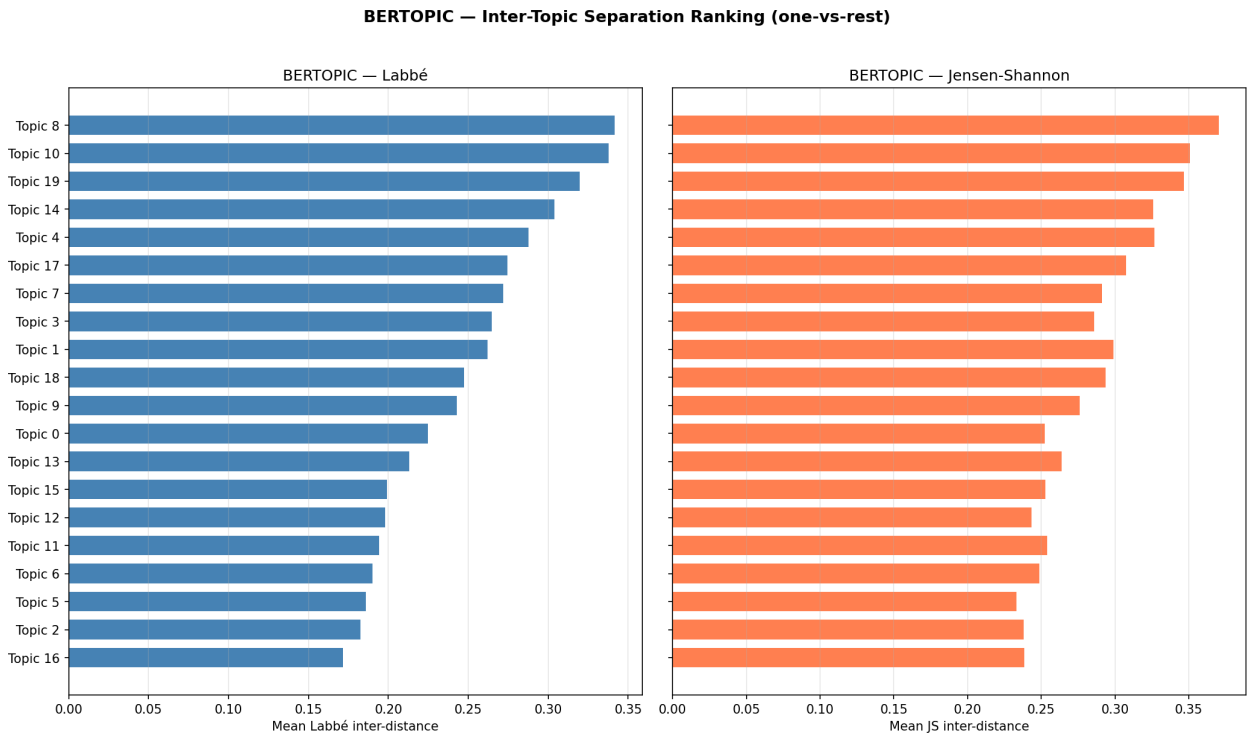

Figure 23: BERTOPIC Ranking

Topic	Distance Labbé moy.	Distance JS moy.
T8: Amour, Perte et Résilience Urbaine	0.3417	0.3703
T10: Amours Perdue et Solitude Urbaine	0.3379	0.3509
T19: Résilience et Évasion Urbaine	0.3198	0.3469

Topics les moins distincts :

Topic	Distance Labbé moy.	Distance JS moy.
T5: Réalité Crue et Résilience Urbaine	0.1861	0.2331
T2: Rébellion et Résilience dans la Rue	0.1827	0.2379
T16: Récits de Résilience et de Réussite	0.1716	0.2384

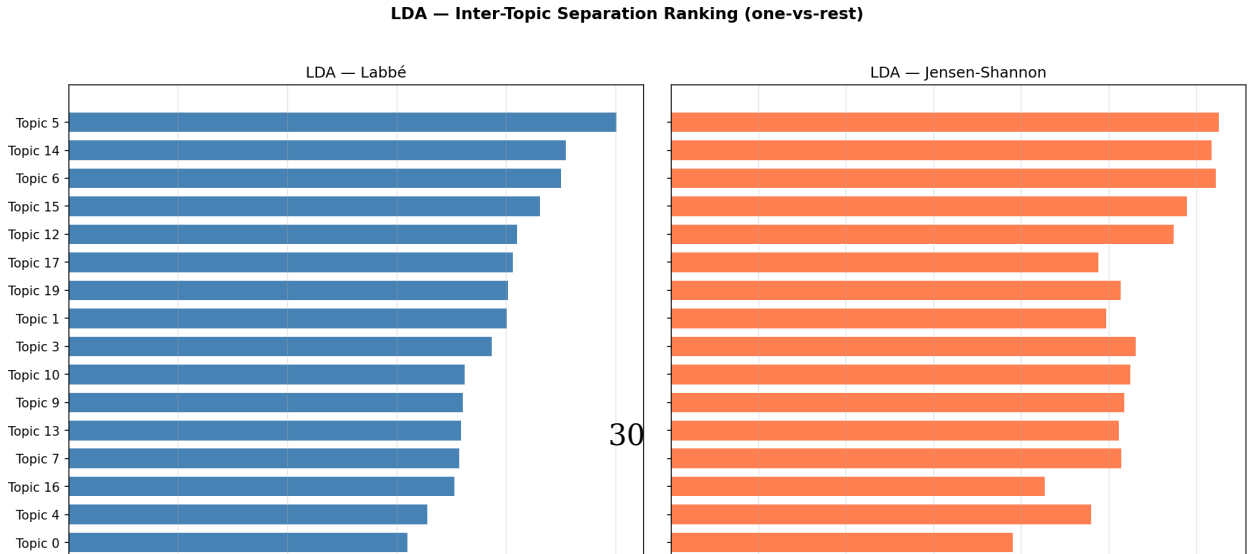

Topics les moins distincts :

Topic	Distance Labbé moy.	Distance JS moy.
T2: fils_pute, j'm'en_fous, j'en_marre, chaud_chaud, fils_putes	0.1498	0.2189
T8: deux_trois, d'en_bas, ferme_yeux, jusqu'au_bout, tirer	0.1467	0.2198
T11: j'me_sens, paroles_rédigées, j'aurais_pu, expliquées_communauté, qu'j'ai	0.1359	0.2056

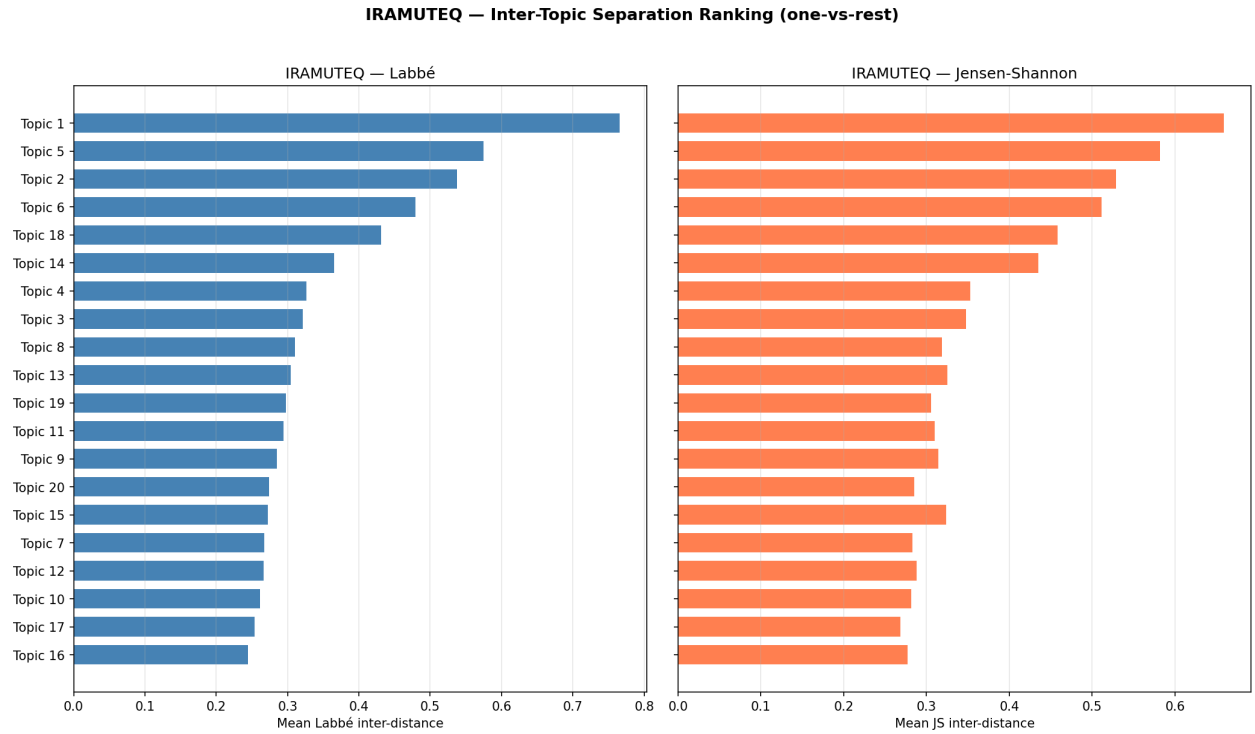

Figure 25: IRAMUTEQ Ranking

Classement des topics par séparation inter-topic (IRAMUTEQ).

Topics les plus distincts :

Topic	Distance Labbé moy.	Distance JS moy.
C1: with, and, that, when, they	0.7653	0.6591
C5: luni, slimes, geeked, shawty, sacki	0.5747	0.5816
C2: chen, ekip, ldo, zuukou, etho	0.5377	0.5288

Topics les moins distincts :

Topic	Distance Labbé moy.	Distance JS moy.
C10: mic, rime, rap, style, mc	0.2616	0.2815
C17: rap, baiser, flow, mec, game	0.2539	0.2683
C16: aller, tess, biff, frérot, hess	0.2443	0.2773

Test d'indépendance χ^2/n (mot × topic) Le test χ^2 sur la table de contingence mot × topic mesure à quel point les fréquences de mots dépendent de l'assignation thématique. Un χ^2/n plus élevé indique que les topics capturent un vocabulaire plus distinctif. Nous comparons les résultats avec et sans lemmatisation pour évaluer l'impact du prétraitement.

La contribution de chaque topic au χ^2 total indique à quel point ce topic utilise un vocabulaire spécifique par rapport à la distribution générale du corpus. Les topics avec une contribution élevée sont lexicalement plus distinctifs — ils utilisent des mots que les autres topics n'utilisent pas (ou beaucoup moins). Une distribution uniforme des contributions (chaque topic ≈ 1/K du total) suggère que tous les topics sont également distinctifs.

Formes de surface (sans lemmatisation)

Model	χ^2	N (tokens)	χ^2/n	Taille vocab.
BERTOPIC	5,085,957	7,716,683	0.6591	60,127
LDA	3,078,063	7,716,683	0.3989	60,127
IRAMUTEQ	10,306,467	7,716,683	1.3356	60,127

Formes lemmatisées

Model	χ^2	N (tokens)	χ^2/n	Taille vocab.
BERTOPIC	4,427,959	7,748,855	0.5714	43,675
LDA	2,459,692	7,748,855	0.3174	43,675
IRAMUTEQ	9,556,352	7,748,855	1.2333	43,675

4. Synthèse et Conclusions

Principales Conclusions

Q1 — Accord entre modèles : L'accord le plus fort est observé entre bertopic vs iramuteq (NMI = 0.1024), tandis que bertopic vs lda montrent l'accord le plus

faible (NMI = 0.0150). Ces valeurs modérées à faibles confirment que chaque modèle capture des aspects distincts du corpus.

Q2 — Séparation des artistes : IRAMUTEQ capture le mieux les signatures artistiques (V de Cramér = 0.3854, 12.2% de spécialistes).

Q3 — Dynamique temporelle : IRAMUTEQ montre la variance temporelle la plus élevée (0.001917), le rendant plus sensible à l'évolution du genre.

Q4 — Chevauchement lexical : Le Jaccard vocabulaire complet entre BERTopic et LDA varie de 0.3639 (seuil=1, vocabulaire fonctionnel partagé) à des valeurs plus faibles aux seuils supérieurs (seuil=5 : 0.3904), confirmant la divergence sur le vocabulaire spécialisé.

Q5 — Homogénéité intra-topic : IRAMUTEQ présente la meilleure homogénéité lexicale (Labbé = 0.9748), IRAMUTEQ la meilleure homogénéité distributionnelle (JS = 0.8185).

χ^2/n — Dépendance mot-topic : IRAMUTEQ montre la plus forte association mot-topic (χ^2/n = 1.3356), indiquant des topics lexicalement plus distinctifs.

Complémentarité des approches : Les trois modèles capturent des aspects distincts du corpus : - **BERTopic** : similarité sémantique via embeddings neuronaux - **LDA** : co-occurrences de mots via modèle génératif probabiliste - **IRAMUTEQ** : mondes lexicaux via classification hiérarchique descendante (ALCESTE)

L'utilisation conjointe de ces trois approches fournit une caractérisation multi-dimensionnelle du corpus, chaque modèle éclairant des facettes complémentaires de la structure thématique.

5. Références Méthodologiques

Métriques d'Accord de Clustering

- Hubert, L., & Arabie, P. (1985). Comparing partitions. Journal of Classification, 2(1), 193-218.
- Strehl, A., & Ghosh, J. (2002). Cluster ensembles: A knowledge reuse framework. Journal of Machine Learning Research, 3, 583-617.
- Vinh, N. X., Epps, J., & Bailey, J. (2010). Information theoretic measures for clusterings comparison: Variants, properties, normalization and correction for chance. Journal of Machine Learning Research, 11, 2837-2854.

Mesures d'Association

- Cramér, H. (1946). Mathematical Methods of Statistics. Princeton University Press.

Théorie de l'Information

- Lin, J. (1991). Divergence measures based on the Shannon entropy. IEEE Transactions on Information Theory, 37(1), 145-151.

Distance Intertextuelle

- Labbé, D., & Labbé, C. (2001). Inter-textual distance and authorship attribution. Corela : cognition, représentation, langage. Journal of Quantitative Linguistics, 8(3), 213-231.
- Labbé, D., & Monière, D. (2003). Le vocabulaire gouvernemental : Canada, Québec, France (1945-2000). Honoré Champion.
- Labbé, C., & Labbé, D. (2007). Experiments on authorship attribution by intertextual distance in English. Journal of Quantitative Linguistics, 14(1), 33-80.
- IRAMUTEQ implementation: gitlab.huma-num.fr/pratinaud/iramuteq (distance-labbe.R)

Cohérence des Topics

- Röder, M., Both, A., & Hinneburg, A. (2015). Exploring the space of topic coherence measures. In Proceedings of the Eighth ACM International Conference on Web Search and Data Mining (WSDM), 399-408.

Validation de Clusters

- Rousseeuw, P. J. (1987). Silhouettes: A graphical aid to the interpretation and validation of cluster analysis. Journal of Computational and Applied Mathematics, 20, 53-65.

Modélisation de Topics

- Grootendorst, M. (2022). BERTopic: Neural topic modeling with a class-based TF-IDF procedure. arXiv preprint arXiv:2203.05794.
- Blei, D. M., Ng, A. Y., & Jordan, M. I. (2003). Latent Dirichlet Allocation. Journal of Machine Learning Research, 3, 993-1022.
- Reinert, M. (1983). Une méthode de classification descendante hiérarchique : application à l'analyse lexicale par contexte. Les Cahiers de l'Analyse des Données, 8(2), 187-198.

Annexes

A. Détails des Runs

- **Timestamp de comparaison:** 2026-03-18 18:20:44
- **Dossier BERTopic:** results/BERTopic/run_20260126_141647_mpnet
- **Dossier LDA:** results/LDA/run_20260224_094852_bigram_only
- **Dossier IRAMUTEQ:** results/IRAMUTEQ/evaluation_20260126_124001

B. Comparaison Mathématique : Labbé vs Jensen-Shannon

Labbé vs Jensen-Shannon : deux regards sur les fréquences Différences fondamentales

Les deux métriques mesurent la similarité lexicale entre textes mais avec des approches différentes.

Distance de Labbé (algorithme IRAMUTEQ) La distance de Labbé, implémentée selon l'algorithme original d'IRAMUTEQ, gère explicitement l'asymétrie de longueur entre textes. L'algorithme procède comme suit :

1. **Identifier** le texte le plus petit (N_{small}) et le plus grand (N_{large})
2. **Normaliser** les comptages du texte plus grand : $n'_i = n_i \times U$ où $U = N_{small}/N_{large}$
3. **Calculer** la somme des différences absolues sur les comptages normalisés
4. **Normaliser** par le dénominateur ajusté

$$D_{\text{Labbé}}(A, B) = \frac{\sum_{i=1}^{V} |n_{small}(i) - n'_{large}(i)|}{N_{small} + \sum_{n'_i \geq 1} n'_i}$$

Cette approche est particulièrement adaptée à la comparaison de textes de longueurs différentes.

Divergence de Jensen-Shannon Mesure la divergence informationnelle entre les distributions de probabilité.

$$D_{\text{JS}}(A, B) = \frac{1}{2} D_{\text{KL}}(P_A \| M) + \frac{1}{2} D_{\text{KL}}(P_B \| M)$$

où $M = (P_A + P_B)/2$ est la distribution moyenne et P représente les fréquences relatives.

Différence fondamentale

Aspect	Labbé	Jensen-Shannon
Entrée	Comptages bruts normalisés	Fréquences relatives
Asymétrie	Gère explicitement	Symétrique
Sensibilité	Linéaire	Logarithmique
Mots rares	Faible impact	**Fort impact**
Fondement	Algorithme IRAMUTEQ	Théorie de l'information

Application au rap français **JS est plus sensible aux mots d'argot spécifiques** à certains artistes/thèmes. **Labbé capture mieux l'homogénéité globale** du vocabulaire courant et gère mieux les différences de longueur entre couplets.

Recommandation : Utiliser les deux métriques en complément : - **Labbé** pour l'homogénéité lexicale générale (robuste aux différences de longueur) - **JS** pour détecter les vocabulaires distinctifs