

Rapport de Comparaison des Modèles de Topics

Contents

Résumé	2
1. Description du Corpus	2
1.1 Vue d'ensemble du jeu de données	2
1.2 Couverture Temporelle	3
1.3 Top 10 Artistes par Nombre de Documents	3
2. Description des Modèles Individuels	4
2.1 BERTopic	4
2.2 LDA	10
2.3 IRAMUTEQ	16
3. Analyse Comparative	18
3.1 Q1 : Les modèles capturent-ils la même structure ?	18
3.2 Q2 : Les modèles séparent-ils les artistes ?	23
3.3 Q3 : Les modèles capturent-ils l'évolution temporelle ?	23
3.4 Q4 : Quelle est la distinctivité lexicale des topics ?	24
3.5 Q5 : Quelle est l'homogénéité lexicale des topics ?	25
Q5-sem — Séparation sémantique (espace d'embeddings)	33
4. Synthèse et Conclusions	35
Principales Conclusions	35
5. Références Méthodologiques	36
Métriques d'Accord de Clustering	36
Mesures d'Association	36
Théorie de l'Information	36
Distance Intertextuelle	37
Cohérence des Topics	37
Validation de Clusters	37
Modélisation de Topics	37
Annexes	37
A. Détails des Runs	37
B. Comparaison Mathématique : Labbé vs Jensen-Shannon	37

Généré le: 2026-07-06 22:37:13

Répertoire de sortie: /home/robin/Code_repo/psycholinguistic2125/JADT_rap_fr/results/com

Résumé

Ce rapport présente une comparaison approfondie de trois approches de modélisation de topics appliquées à un corpus de paroles de rap français : **BERTopic** (embeddings neuronaux), **LDA** (modèle génératif probabiliste), et **IRAMUTEQ** (classification lexicale par la méthode ALCESTE de Reinert). L'analyse se décompose comme suit :

1. **Description du corpus** : caractérisation statistique du corpus (nombre de documents, artistes, couverture temporelle, distribution par décennie).
2. **Description des modèles individuels** : paramètres, métriques de qualité (cohérence C_v , silhouette), distribution des topics et séparation des artistes pour chaque modèle.
3. **Q1 — Accord entre modèles** : évaluation de la similarité des clusterings à l'aide de l'ARI (Hubert & Arabie, 1985), la NMI (Strehl & Ghosh, 2002) et l'AMI (Vinh et al., 2010), avec analyse des correspondances inter-topics.
4. **Q2 — Séparation des artistes** : mesure de l'association artiste-topic par le V de Cramér (Cramér, 1946) et analyse des résidus de Pearson standardisés.
5. **Q3 — Dynamique temporelle** : analyse de la variance des distributions de topics dans le temps et de la divergence de Jensen-Shannon entre périodes biannuelles.
6. **Q4 — Distinctivité lexicale** : évaluation du chevauchement du vocabulaire entre topics par la distance de Jaccard et analyse inter-modèles.
7. **Q5 — Homogénéité intra-topic** : mesure de la cohérence lexicale des clusters par les distances de Labbé (Labbé & Labbé, 2001) et de Jensen-Shannon (Lin, 1991), calculées sur des documents tokenisés avec spaCy.
8. **Synthèse et recommandations** : bilan comparatif des trois modèles et recommandations d'usage.

1. Description du Corpus

Cette section présente une vue d'ensemble du corpus de paroles de rap français utilisé pour la modélisation de topics. Le corpus est constitué de couplets individuels extraits de chansons, avec des métadonnées incluant l'artiste, le titre et l'année.

1.1 Vue d'ensemble du jeu de données

Métrique	Valeur
Documents totaux (couplets)	115,805
Période couverte	1992 - 2023
Artistes uniques	605
Année moyenne	2014.7
Année médiane	2017
Docs moyens par artiste	191.4
Docs médians par artiste	137
Artiste le plus prolifique	JuL (2,878 docs)

1.2 Couverture Temporelle

Le corpus couvre plus de trois décennies de rap français, de l'ère pionnière des années 1990 à la scène contemporaine.




Figure 1: Distribution

Figure 1.1 : Gauche - Nombre de documents par année. Droite - Distribution de la productivité des artistes (échelle log).

Figure 1.2 : Distribution du corpus par décennie.

Décennie	Documents	% du Corpus
1990s	4,517	3.9%
2000s	19,605	16.9%
2010s	60,895	52.6%
2020s	30,788	26.6%

1.3 Top 10 Artistes par Nombre de Documents

Rang	Artiste	Documents	% du Corpus	% Cumulatif
1	JuL	2,878	2.5%	2.5%
2	La Fouine	1,191	1.0%	3.5%
3	Rohff	1,095	0.9%	4.5%
4	Sexion d'Assaut	1,023	0.9%	5.3%
5	Alkpote	889	0.8%	6.1%
6	Naps	854	0.7%	6.8%
7	Disiz	849	0.7%	7.6%
8	Swift Quad	797	0.7%	8.3%
9	IAM	745	0.6%	8.9%
10	Sinik	744	0.6%	9.6%

Concentration du corpus : Les 10 premiers artistes représentent 9.6% du corpus, indiquant une distribution d'artistes diverse.




Figure 2: Decades

2. Description des Modèles Individuels

Cette section présente la configuration, les métriques de qualité et les topics découverts par chaque modèle. Nous incluons les visualisations spécifiques à chaque modèle pour contextualiser l’analyse comparative.

2.1 BERTopic

Dossier du run: results/BERTopic/run_20260706_220123_solon

BERTopic (Grootendorst, 2022) est un modèle de topics neuronal utilisant des embeddings de transformers pour la représentation des documents, UMAP pour la réduction de dimensionnalité, et le clustering. Les topics sont représentés via pondération c-TF-IDF, avec labellisation optionnelle par OpenAI et KeyBERT.

Paramètres

Paramètre	Valeur
embedding_model	OrdalieTech/Solon-embeddings-large-0.1
embedding_key	solon

Paramètre	Valeur
clustering_algorithm	kmeans
n_clusters	20
hdbscan_params	None
agglomerative_params	None
umap_params	n_neighbors=15, n_components=5, min_dist=0.0, metric=cosine, random_state=42
num_words_per_topic	30
use_openai	True
include_keybert	False
interactive_html	True

Qualité du Clustering

Métrique	Valeur	Interprétation
Silhouette (UMAP)	0.2303	Modéré

Le score de silhouette (Rousseeuw, 1987) mesure la séparation des clusters.




Figure 3: Silhouette

Distribution des Topics

Métrique	Valeur	Interprétation
Nombre de topics	20	-
Ratio d'imbalance	147.47	Très déséquilibré
Entropie de distribution	0.976	Quasi uniforme

Définitions des métriques :

- **Ratio d'imbalance** = $\max(\text{compte_topic}) / \min(\text{compte_topic})$. Mesure l'inégalité des tailles de topics.
- **Entropie de distribution** (normalisée) = $-\sum(p_i \times \log(p_i)) / \log(n_topics)$. Intervalle $[0,1]$: 1 = uniforme.




Figure 4: Topic Distribution

Distribution des documents par topic.

Séparation des Artistes

Métrique	Valeur	Description
% Spécialistes	6.6%	Artistes avec >50% dans un topic
% Modérés	20.6%	Artistes avec 25-50% dans le topic dominant
% Généralistes	72.8%	Artistes répartis sur plusieurs topics
Indice de spécialisation	0.240	Concentration moyenne
Divergence JS	0.513	Divergence des profils d'artistes

Heatmap de distribution des artistes par topic.

Profils de spécialisation des artistes.




Figure 5: Artist-Topic Heatmap




Figure 6: Artist Specialization

Dynamique Temporelle

Métrique	Valeur
Variance moyenne des topics	0.000770
JS annuel moyen	N/A




Figure 7: Annual JS

Divergence JS entre années consécutives.

Évolution des topics dans le temps.

Vue d'ensemble des Topics **Topic 0** — “Solitude et Quête d’Identité”

- **c-TF-IDF:** je, de, la, le, que, est, ai, et, les, qu
- **KeyBERT (0 terms):**

Topic 1 — *Réalité de la Rue et Résistance*

- **c-TF-IDF:** la, les, le, on, est, dans, pas, de, des, tu
- **KeyBERT (0 terms):**

Topic 2 — *Vie de Rue et Rébellion Urbaine*

- **c-TF-IDF:** la, dans, le, suis, pas, est, les, on, en, ai
- **KeyBERT (0 terms):**

Topic 3 — *Authenticité et Lutte dans le Rap*

- **c-TF-IDF:** le, de, est, les, la, rap, et, pas, un, on
- **KeyBERT (0 terms):**

Topic 4 — *Vengeance, Trahison et Rébellion Urbaine*

- **c-TF-IDF:** les, la, de, est, le, pas, un, des, tu, comme




Figure 8: Year-Topic Heatmap

- **KeyBERT (0 terms):**

Topic 5 — *Amour, Rupture et Solitude*

- **c-TF-IDF:** je, tu, moi, que, pas, toi, ai, est, qu, me
- **KeyBERT (0 terms):**

Topic 6 — *Identité et Lutte Sociale*

- **c-TF-IDF:** de, les, la, on, est, le, et, des, qu, que
- **KeyBERT (0 terms):**

Topic 7 — *Résilience face à la Violence et l'Injustice*

- **c-TF-IDF:** de, la, le, les, et, des, un, est, dans, que
- **KeyBERT (0 terms):**

Topic 8 — *Quête de Richesse et Détresse Urbaine*

- **c-TF-IDF:** la, le, on, les, pas, est, dans, de, ai, des
- **KeyBERT (0 terms):**

Topic 9 — *Titre du thème : "Lutte et Résilience dans la Rue"*

- **c-TF-IDF:** de, la, est, pas, les, le, on, ai, qu, et
- **KeyBERT (0 terms):**

Topic 10 — *Résilience et Rébellion dans la Rue*

- **c-TF-IDF:** pas, la, les, est, tu, on, ai, de, qu, le
- **KeyBERT (0 terms):**

Topic 11 — *Réflexion sur la Vie de Rue*

- **c-TF-IDF:** la, les, de, est, le, on, des, pas, dans, et
- **KeyBERT (0 terms):**

Topic 12 — *Résilience et Révolte des Quartiers*

- **c-TF-IDF:** les, la, de, est, on, le, des, pas, et, dans
- **KeyBERT (0 terms):**

Topic 13 — *Vie de Rue et Évasion Urbaine*

- **c-TF-IDF:** elle, la, est, pas, tu, le, dans, les, de, je
- **KeyBERT (0 terms):**

Topic 14 — *Trahison et Désillusion dans les Relations*

- **c-TF-IDF:** pas, je, ai, que, est, de, la, qu, tu, le
- **KeyBERT (0 terms):**

... et 5 autres topics

Projection UMAP des embeddings colorés par topic.

2.2 LDA

Dossier du run: results/LDA/run_20260706_171018_both

Latent Dirichlet Allocation (Blei, Ng & Jordan, 2003) est un modèle génératif probabiliste représentant les documents comme mélanges de topics, où chaque topic est une distribution sur les mots. Cette implémentation utilise Gensim avec prétraitement n-gram.

Paramètres

Paramètre	Valeur
backend	tomotopy
num_topics	20
alpha	optimized
eta	0.01 (fixed)

Paramètre	Valeur
learned_alpha	[0.1164388507604599, 0.07838124781847, 0.30533406138420105, 0.08740535378456116, 0.030320167541503906, 0.2100149691104889, 0.2892478108406067, 0.12688910961151123, 0.22516897320747375, 0.3718010187149048, 0.1383122354745865, 0.1755695641040802, 0.2608986794948578, 0.09985540807247162, 0.09110520035028458, 0.2588096261024475, 0.2526785731315613, 0.3634151220321655, 0.1991192102432251, 0.20089060068130493]
passes	15
iterations	400
gibbs_iterations	1000
min_word_len	2
min_doc_freq	5
max_doc_freq_ratio	0.5
use_ngrams	both
ngram_min_count	10
ngram_threshold	50
legacy_stopwords	False
dedup	False
dedup_method	None
num_docs_before_dedup	115805
num_docs_removed_dedup	0
num_words_per_topic	30
keep_all_the_document	True

Scores de Cohérence

Métrique	Valeur	Interprétation
Cohérence C_v	0.4156	Modéré
Cohérence UMass	-2.6848	Modéré

La cohérence C_v (Röder et al., 2015) mesure la cohérence sémantique des mots des topics.




Figure 9: UMAP





Figure 10: Coherence

Distribution des Topics

Métrique	Valeur	Interprétation
Nombre de topics	20	-
Ratio d'imbalance	9.85	Déséquilibré
Entropie de distribution	0.954	Quasi uniforme

Définitions des métriques :

- **Ratio d'imbalance** = $\max(\text{compte_topic}) / \min(\text{compte_topic})$. Mesure l'inégalité des tailles de topics.
- **Entropie de distribution** (normalisée) = $-\sum(p_i \times \log(p_i)) / \log(n_topics)$. Intervalle $[0,1]$: 1 = uniforme.






Figure 12: Artist-Topic Heatmap




Figure 13: Artist Specialization

Heatmap de distribution des artistes par topic.
Profils de spécialisation des artistes.

Dynamique Temporelle

Métrique	Valeur
Variance moyenne des topics	0.000457
JS annuel moyen	0.0524




Figure 14: Annual JS

Divergence JS entre années consécutives.
Évolution des topics dans le temps.

Vue d'ensemble des Topics

Topic	Mots clés
0	qu'elle, j'aime, belle, soir, bonne, danse, bébé, aime, sais, fille
1	négro, négros, jeune, j'veux, j'arrive, noir, pétasse, j'fais, black, toujours
2	qu'on, gens, qu'il, jamais, besoin, vie, sais, toujours, qu'ils, vrai
3	qu'on, comment, bon, vas-y, qu'est-ce, gars, sais, monde, allez, fou
4	i'm, your, but, it's, just, don't, night, now, time, when

Topic	Mots clés
5	rue, street, frères, mecs, ghetto, parle, baise, tess, keufs, ici
6	vite, ici, tête, coup, merde, passe, gars, qu'on, rue, place
7	deux, d'la, tête, soir, j'fais, j'me, fume, roule, trois, beuh
8	fin, monde, deux, grand, nom, terre, corps, sens, puis, aucun
9	d'la, j'me, j'veux, j'fais, j'vais, c'que, j'sais, vie, j'vois, qu'on
10	vie, nuit, loin, jour, mort, seul, ville, encore, soir, noir
11	france, monde, qu'on, guerre, frères, ici, pays, jeunes, qu'ils, haine
12	pute, j'te, putain, gueule, cul, sale, vas, baise, mère, chatte
13	zone, marseille, j'fais, quartier, nique, j'vais, jaloux, vois, mets, sang
14	pourquoi, cœur, bébé, j'te, sais, dis-moi, j'veux, jamais, j'vais, mama

... et 5 autres topics

Projection PCA des distributions topic-mot.

2.3 IRAMUTEQ

Dossier du run: results/IRAMUTEQ/evaluation_20260126_124001

IRAMUTEQ implémente la méthode ALCESTE de Reinert (Reinert, 1983), qui effectue une classification hiérarchique descendante sur les segments de texte, identifiant les mondes lexicaux.

Paramètres

Paramètre	Valeur
method	IRAMUTEQ
n_classes	20
n_documents	115805
min_docs_per_artist	10
top_artists_per_topic	20

Distribution des Topics




Figure 15: Year-Topic Heatmap

Métrique	Valeur	Interprétation
Nombre de topics	20	-
Ratio d'imbalance	31.70	Très déséquilibré
Entropie de distribution	2.709	Quasi uniforme

Définitions des métriques :

- **Ratio d'imbalance** = $\max(\text{compte_topic}) / \min(\text{compte_topic})$. Mesure l'inégalité des tailles de topics.
- **Entropie de distribution** (normalisée) = $-\sum(p_i \times \log(p_i)) / \log(n_topics)$. Intervalle $[0,1]$: 1 = uniforme.

Distribution des documents par topic.

Séparation des Artistes

Métrique	Valeur	Description
% Spécialistes	12.2%	Artistes avec >50% dans un topic
% Modérés	44.3%	Artistes avec 25-50% dans le topic dominant
% Généralistes	43.4%	Artistes répartis sur plusieurs topics
Indice de spécialisation	0.364	Concentration moyenne
Divergence JS	0.541	Divergence des profils d'artistes

Heatmap de distribution des artistes par topic.

Profil de spécialisation des artistes

Topic	Mots clés
3	jul, marseille, gadji, moto, poto, fumette, bdh, zone, dégun, miss
4	hey, brr, yah, gucci, grr, gang, bébé, mmh, woh, fendi
5	luni, slimes, geeked, shawty, sacki, voidd, drip, majdon, ola, slime
6	sexion, wati, assaut, 9ème, gims, jeryzoos, akhi, maska, llefa, 3ème
7	bitch, négro, flow, meuf, club, weed, flex, boy, yo, dj
8	france, peuple, pays, politique, afrique, communauté, rédiger, justice, état, système
9	cli, ients, binks, détailler, midi, minuit, visser, gue, terrain, pe
10	mic, rime, rap, style, mc, hip_hop, rimer, beat, micro, texte
11	art, swift, acide, artère, guad, tekk, carcasse, delleck, corps, nikkfurie
12	chose, impression, penser, fois, temps, gens, question, moment, envie, vraiment
13	amour, aimer, sentiment, mentir, couple, amoureux, relation, femme, coeur, défaut
14	2mz, qlf, sourou, igd, pnl, adios, amigo, benab, igo, rio
15	billet, violet, monnaie, vert, liasse, euro, poche, payer, charbonner, bleu

... et 5 autres topics

3. Analyse Comparative

3.1 Q1 : Les modèles capturent-ils la même structure ?

Question de recherche : Les différentes approches découvrent-elles des structures similaires ?

Contexte Méthodologique Nous utilisons trois métriques d'accord de clustering :

Adjusted Rand Index (ARI) — Hubert, L., & Arabie, P. (1985)

L'indice de Rand ajusté mesure la similarité entre deux clusterings, corrigé par le hasard. Il calcule le nombre d'accords de paires (toutes deux dans le même cluster ou toutes deux dans des clusters différents), normalisé par la valeur attendue sous un modèle aléatoire. $ARI = (RI - RI_{attendu}) / (RI_{max} - RI_{attendu})$. Intervalle : $[-1, 1]$, où 1 = accord parfait, 0 = aléatoire, <0 = inférieur au hasard.




Figure 16: PCA




Figure 17: Topic Distribution

Normalized Mutual Information (NMI) — Strehl, A., & Ghosh, J. (2002)

La NMI mesure la dépendance mutuelle entre deux clusterings en utilisant la théorie de l'information. Elle quantifie dans quelle mesure la connaissance d'un clustering réduit l'incertitude sur l'autre. $NMI = 2 \times I(X;Y) / (H(X) + H(Y))$, où I est l'information mutuelle et H l'entropie. Intervalle : $[0, 1]$, où 1 = clusterings identiques, 0 = indépendants.

Résultats

Paire	ARI	NMI	Interprétation
bertopic_vs_lda	0.0746	0.1618	Accord faible
bertopic_vs_iramuteq	0.0857	0.1769	Accord faible
lda_vs_iramuteq	0.1056	0.2050	Accord faible

Observations clés :

1. **Meilleur accord** : lda_vs_iramuteq (NMI = 0.2050)
2. **Accord le plus faible** : bertopic_vs_lda (NMI = 0.1618)
3. **Pattern général** : Les scores d'accord relativement faibles ($NMI < 0.5$) suggèrent que chaque modèle capture des aspects distincts :
 - BERTopic : similarité sémantique (sens)
 - LDA : co-occurrences de mots (distribution)
 - IRAMUTEQ : classification lexicale (vocabulaire)

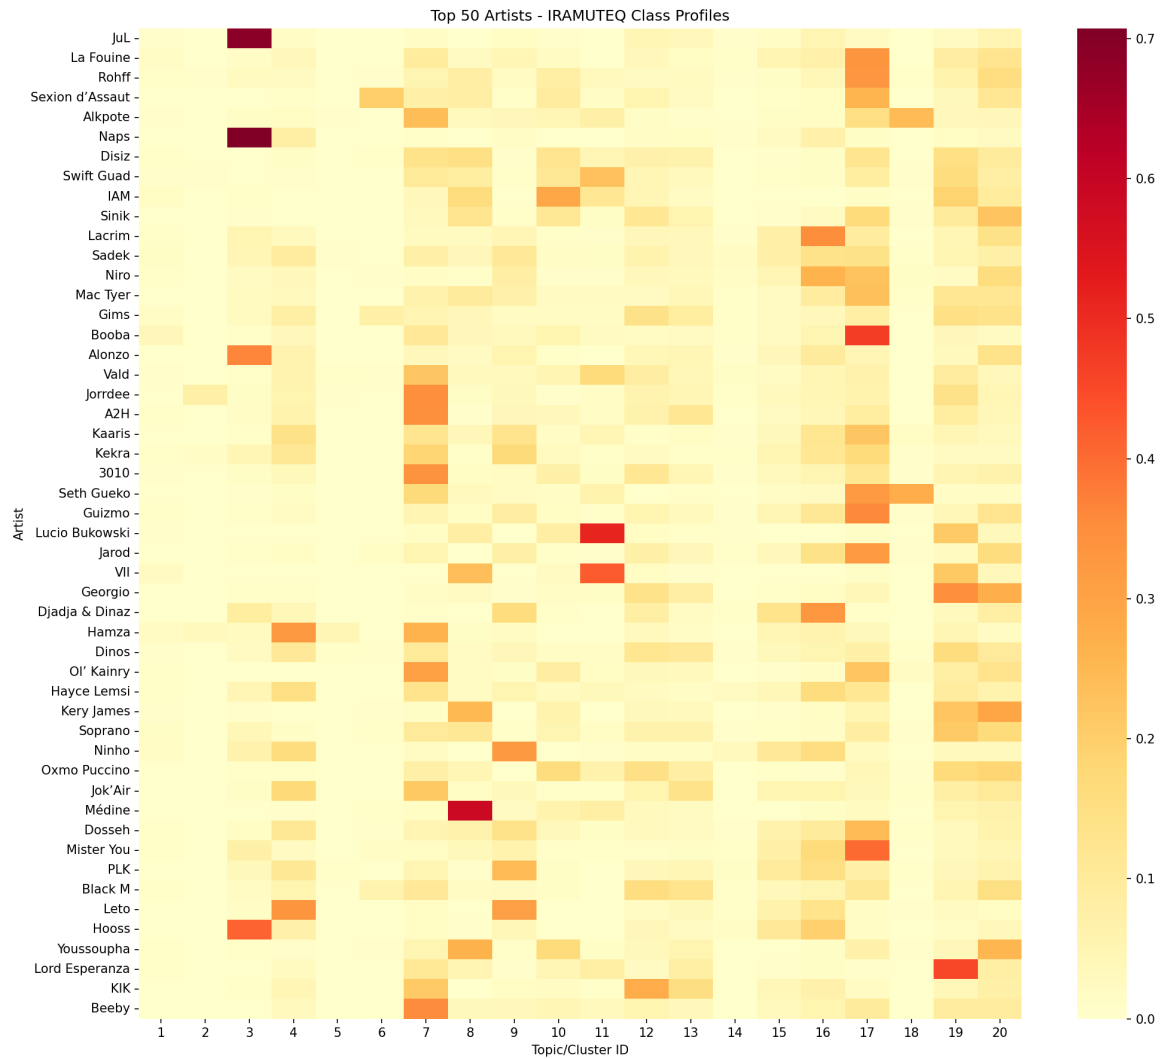


Figure 18: Artist-Topic Heatmap




Figure 19: Artist Specialization




Figure 20: Annual JS




Figure 21: Year-Topic Heatmap

3.2 Q2 : Les modèles séparent-ils les artistes ?

Question de recherche : Les topics capturent-ils des signatures stylistiques propres aux artistes ?

Contexte Méthodologique V de Cramér — Cramér, H. (1946)

Le V de Cramér mesure la force d'association entre deux variables catégorielles. Il est dérivé de la statistique du chi-deux : $V = \sqrt{(\chi^2 / (n \times \min(k-1, r-1)))}$, où k et r sont le nombre de catégories. V normalise le chi-deux par la taille de l'échantillon et la dimensionnalité, permettant la comparaison entre tables de tailles différentes. Intervalle : [0, 1], où 0 = aucune association, 1 = association parfaite.

Résultats

Modèle	V de Cramér	Interprétation
BERTOPIC	0.2593	Association modérée
LDA	0.3138	Association forte
IRAMUTEQ	0.3854	Association forte

Observations clés :

1. **Séparation la plus forte :** IRAMUTEQ (V = 0.3854)
2. **Spécialistes :** La proportion varie selon les modèles.
3. **Généralistes :** Artistes répartis sur plusieurs topics = thèmes divers.

3.3 Q3 : Les modèles capturent-ils l'évolution temporelle ?

Question de recherche : Les distributions de topics changent-elles dans le temps ?

Contexte Méthodologique Variance Temporelle : Mesure la fluctuation des topics au fil du temps.

Résultats

Modèle	Variance Temporelle	Topic le plus variable	Variance max	Interprétation
BERTOPIC	0.000794	3	0.004110	Stable
LDA	0.000472	18	0.001878	Stable
IRAMUTEQ	0.001917	9	0.015929	Dynamique modérée

Observations clés :

1. **Le plus dynamique :** IRAMUTEQ montre la variance la plus élevée.

2. **Transitions majeures** : Une divergence JS élevée entre décennies indique des changements.
3. **Topics stables vs évolutifs** : Faible variance = thèmes pérennes, haute variance = tendances.

3.4 Q4 : Quelle est la distinctivité lexicale des topics ?

Question de recherche : Les topics représentent-ils des vocabulaires distincts ?

Contexte Méthodologique Distance de Jaccard : Mesure la distinctivité du vocabulaire entre topics.

Distinctivité : Distance de Jaccard moyenne entre vocabulaires de topics.

Résultats

Modèle	Distance de Jaccard Moyenne	Interprétation
BERTOPIC	0.4025	Chevauchement significatif
LDA	0.9476	Topics très distincts
IRAMUTEQ	0.9964	Topics très distincts

Observations clés :

1. **LDA et IRAMUTEQ** montrent une haute distinctivité (>0.9).
2. **BERTopic** peut montrer une distinctivité plus faible (embeddings sémantiques).

Chevauchement Lexical Inter-Modèles (Vocabulaire Complet) Pour évaluer le recouvrement lexical entre les topics correspondants de BERTopic et LDA, nous calculons l'indice de Jaccard sur le **vocabulaire complet** des documents assignés à chaque topic (et non sur les seuls mots représentatifs extraits par c-TF-IDF ou probabilité). Nous faisons varier le seuil de fréquence minimale pour distinguer le vocabulaire fonctionnel partagé (seuil bas, Jaccard élevé) du vocabulaire thématique spécifique (seuil élevé, Jaccard plus faible). Un Jaccard décroissant avec le seuil indique que les modèles divergent sur les termes spécialisés tout en partageant le socle lexical commun.

Seuil min. freq.	Jaccard moyen	Paires
1	0.4412	20
5	0.5046	20
20	0.5031	20

3.5 Q5 : Quelle est l'homogénéité lexicale des topics ?

Question de recherche : Les documents d'un même topic sont-ils lexicalement similaires ?

Des distances intra-topic plus faibles indiquent des clusters plus cohérents.

Contexte Méthodologique Nous calculons les distances par paires entre documents du même topic. Deux métriques complémentaires :

Distance	Ce qu'elle capture	Justification scientifique
Jensen-Shannon	Divergence distributionnelle	Largement utilisée en NLP. Fondée sur la théorie de l'information. Bornée [0,1].
Labbé	Homogénéité lexicale	Standard JADT pour la stylométrie française.

Jensen-Shannon — Lin, J. (1991)

La distance JS est la racine carrée de la divergence JS, une mesure symétrique de similarité entre distributions de probabilité. `scipy.spatial.distance.jensenshannon()` retourne directement cette valeur de distance. La distance JS est une métrique propre satisfaisant l'inégalité triangulaire. Intervalle : [0, 1], où 0 = distributions identiques, 1 = maximalement différentes.

Labbé — Labbé, D., & Labbé, C. (2001)

La distance de Labbé mesure la similarité lexicale entre deux textes, implémentée selon l'algorithme original d'IRAMUTEQ. Elle gère explicitement l'asymétrie de longueur entre textes : 1) Identifier le texte plus petit (N_{small}) et plus grand (N_{large}) 2) Normaliser les comptages du texte plus grand : $n'_i = n_i \times U$ où $U = N_{small}/N_{large}$ 3) Calculer la somme des différences absolues sur les comptages normalisés 4) Normaliser : $D = \sum |n_{small} - n'_{large}| / (N_{small} + \sum (n' \text{ où } n' \geq 1))$ Cette métrique est le standard en stylométrie française et dans la communauté JADT pour l'attribution d'auteur. Intervalle : [0, 1], où 0 = vocabulaires identiques, 1 = aucun chevauchement.

Résultats Distance Jensen-Shannon (Distributionnelle)

Modèle	Distance Moyenne	Écart-type	Topics	Interprétation
BERTOPIC	0.8171	0.0116	20	Très hétérogène
LDA	0.8200	0.0028	20	Très hétérogène
IRAMUTEQ	0.8185	0.0069	20	Très hétérogène

Distance de Labbé (Lexicale)

Modèle	Distance Moyenne	Écart-type	Topics	Interprétation
BERTOPIC	0.9738	0.0142	20	Très hétérogène
LDA	0.9776	0.0052	20	Très hétérogène
IRAMUTEQ	0.9748	0.0131	20	Très hétérogène

Observations clés :

1. **Meilleure homogénéité distributionnelle (JS)** : BERTOPIC montre la distance moyenne la plus faible (0.8171).
2. **Meilleure homogénéité lexicale (Labbé)** : BERTOPIC montre la distance moyenne la plus faible (0.9738).
3. **Complémentarité** : JS capture la similarité distributionnelle, Labbé le chevauchement lexical absolu.

Analyse par Topic Top 5 topics les plus et les moins homogènes (distance JS) :

BERTOPIC

Topics les plus homogènes :

Topic	Distance JS Moyenne	Documents
19	0.7672	55
9	0.8158	5885
5	0.8166	7417
14	0.8167	4800
3	0.8171	7832

Topics les moins homogènes :

Topic	Distance JS Moyenne	Documents
8	0.8215	5951
4	0.8219	7615
1	0.8221	7922
13	0.8222	5068
2	0.8232	7916

LDA

Topics les plus homogènes :

Topic	Distance JS Moyenne	Documents
4	0.8141	1318
9	0.8153	12145

Topic	Distance JS Moyenne	Documents
16	0.8158	7067
14	0.8170	3150
2	0.8181	7835

Topics les moins homogènes :

Topic	Distance JS Moyenne	Documents
19	0.8219	9442
3	0.8221	2230
1	0.8223	2608
7	0.8243	3265
8	0.8251	4297

IRAMUTEQ

Topics les plus homogènes :

Topic	Distance JS Moyenne	Documents
1	0.7899	704
12	0.8160	7853
13	0.8160	5362
20	0.8165	11508
5	0.8172	363

Topics les moins homogènes :

Topic	Distance JS Moyenne	Documents
18	0.8219	709
8	0.8222	7549
7	0.8224	10727
4	0.8228	6950
11	0.8234	4837

Voir Annexe B pour une explication des métriques de distance.

Analyse par Configuration de Distance Nous calculons les distances selon 4 configurations complémentaires pour évaluer différents aspects de la qualité des topics :

Configuration	Ce qu'elle mesure	Guide d'interprétation
Intra-topic (paires)	Homogénéité	Plus bas = meilleur
Inter-topic (paires)	Séparation	Plus haut = meilleur
Intra-topic (agrégé) (n=20)	Homogénéité	Plus bas = meilleur
Inter-topic (agrégé) (n=20)	Séparation	Plus haut = meilleur

Note : L'agrégation de 20 couplets crée des unités textuelles plus comparables pour la distance de Labbé, qui est sensible à la longueur des textes.

Intra-topic (paires)

*Distances entre paires de documents du même topic. Mesure l'**homogénéité interne** : des distances faibles indiquent des topics cohérents.*

Modèle	JS	Labbé
BERTOPIC	0.8171	0.9738
LDA	0.8200	0.9776
IRAMUTEQ	0.8185	0.9748

Inter-topic (paires)

*Distances entre documents du topic et documents hors du topic. Mesure la **séparation** : des distances élevées indiquent des topics bien distincts.*

Modèle	JS	Labbé
BERTOPIC	0.8221	0.9816
LDA	0.8228	0.9828
IRAMUTEQ	0.8229	0.9832

Intra-topic (agrégé) (n=20)

Comme intra-paires, mais en agrégeant n couplets ensemble. Réduit la sensibilité de Labbé aux différences de longueur.

Modèle	JS	Labbé
BERTOPIC	0.6919	0.7435
LDA	0.7085	0.7658
IRAMUTEQ	0.7022	0.7543

Inter-topic (agrégé) (n=20)

Comme inter-paires, mais avec documents agrégés. Plus robuste pour les comparaisons de séparation.

Modèle	JS	Labbé
BERTOPIC	0.7289	0.8018
LDA	0.7332	0.8110
IRAMUTEQ	0.7345	0.8132

Synthèse des 4 configurations :

- **Meilleure homogénéité (JS):** BERTOPIC (0.8171)
- **Meilleure homogénéité (Labbé):** BERTOPIC (0.9738)
- **Meilleure séparation (JS):** IRAMUTEQ (0.8229)
- **Meilleure séparation (Labbé):** IRAMUTEQ (0.9832)

Stabilisation de la distance de Labbé par agrégation Cette analyse montre comment la distance de Labbé évolue en fonction du nombre de couplets agrégés. La distance de Labbé étant sensible à la longueur des textes, l'agrégation de plusieurs couplets produit des unités textuelles plus comparables et des distances plus stables.

Plage d'agrégation : de 8 à 11 documents (>500 mots/unité, ≥ 5 unités/topic), 2 points. Taille minimale de topic (tous modèles) : 55 documents.




Figure 22: Aggregation Curve

Évolution de la distance de Labbé intra-topic (gauche) et inter-topic (droite) en fonction de la taille d'agrégation.

Classement de la séparation inter-topic Pour chaque modèle, les topics sont classés par leur distance inter-topic moyenne (un-contre-reste). Des distances plus élevées indiquent des topics lexicalement plus distincts du reste du corpus.

Classement des topics par séparation inter-topic (BERTOPIC).

Topics les plus distincts :




Figure 23: BERTOPIC Ranking

Topic	Distance Labbé moy.	Distance JS moy.
T19: Quête d'Amour et Lutte Personnelle	0.8264	0.7349
T5: Amour, Rupture et Solitude	0.3963	0.3860
T15: Relations Complexes et Désillusions Amoureuses	0.3400	0.3574

Topics les moins distincts :

Topic	Distance Labbé moy.	Distance JS moy.
T10: Résilience et Rébellion dans la Rue	0.2082	0.2563

Topic	Distance Labbé moy.	Distance JS moy.
T11: Réflexion sur la Vie de Rue	0.2073	0.2528
T16: Des Cendres à l'Ambition : Luttés et Résilience	0.2011	0.2522




Figure 24: LDA Ranking

Classement des topics par séparation inter-topic (LDA).

Topics les plus distincts :

Topic	Distance Labbé moy.	Distance JS moy.
T4: i'm, your, but, it's, just	0.6490	0.5769
T14: pourquoi, cœur, bébé, j'te, sais	0.4290	0.4311
T1: négro, négros, jeune, j'veux, j'arrive	0.4183	0.4185

Topics les moins distincts :

Topic	Distance Labbé moy.	Distance JS moy.
T6: vite, ici, tête, coup, merde	0.2367	0.2603
T2: qu'on, gens, qu'il, jamais, besoin	0.2362	0.2611
T9: d'la, j'me, j'veux, j'fais, j'vais	0.1682	0.2086




Figure 25: Iramuteq Ranking

Classement des topics par séparation inter-topic (IRAMUTEQ).

Topics les plus distincts :

Topic	Distance Labbé moy.	Distance JS moy.
C1: with, and, that, when, they	0.7653	0.6591
C5: luni, slimes, geeked, shawty, sacki	0.5747	0.5816
C2: chen, ekip, ldo, zuukou, etho	0.5377	0.5288

Topics les moins distincts :

Topic	Distance Labbé moy.	Distance JS moy.
C10: mic, rime, rap, style, mc	0.2616	0.2815
C17: rap, baiser, flow, mec, game	0.2539	0.2683
C16: aller, tess, biff, frerot, hess	0.2443	0.2773

Test d'indépendance χ^2/n (mot $\times$ topic) Le test χ^2 sur la table de contingence mot $\times$ topic mesure à quel point les fréquences de mots dépendent de l'assignation thématique. Un χ^2/n plus élevé indique que les topics capturent un vocabulaire plus distinctif. Nous comparons les résultats avec et sans lemmatisation pour évaluer l'impact du prétraitement.

La contribution de chaque topic au χ^2 total indique à quel point ce topic utilise un vocabulaire spécifique par rapport à la distribution générale du corpus. Les topics avec une contribution élevée sont lexicalement plus distinctifs — ils utilisent des mots que les autres topics n'utilisent pas (ou beaucoup moins). Une distribution uniforme des contributions (chaque topic $\approx 1/K$ du total) suggère que tous les topics sont également distinctifs.

Formes de surface (sans lemmatisation)

Model	χ^2	N (tokens)	χ^2/n	Taille vocab.
BERTOPIC	6,311,868	7,716,683	0.8180	60,127
LDA	8,751,198	7,716,683	1.1341	60,127
IRAMUTEQ	10,306,467	7,716,683	1.3356	60,127

Formes lemmatisées

Model	χ^2	N (tokens)	χ^2/n	Taille vocab.
BERTOPIC	5,457,777	7,748,855	0.7043	43,675
LDA	7,736,897	7,748,855	0.9985	43,675
IRAMUTEQ	9,556,352	7,748,855	1.2333	43,675

Q5-sem — Séparation sémantique (espace d'embeddings)

Contrepartie de la Q5 lexicale dans l'espace des embeddings de phrases : mêmes tailles d'agrégation, même échantillonnage de paires (graine 42), la distance cosinus remplaçant la distance de Labbé. Ces métriques sont **alignées par construction** avec les méthodes à base d'embeddings — tout comme le χ^2/n l'est avec le critère de Reinert — et sont rapportées par souci de transparence, non comme arbitre de la qualité globale. Non-circularité : chaque partition est évaluée dans des espaces d'embeddings *différents* de celui sur lequel BERTopic a été entraîné (« selon »).

SR lexical (Labbé)

Model	n=8	n=11
BERTOPIC	1.0436	1.0546
LDA	1.0318	1.0394
IRAMUTEQ	1.0434	1.0536




Figure 26: Semantic aggregation curve — e5

Espace : e5 *Qualité de clustering (indices internes). Silhouette cosinus sur échantillon stratifié ; Calinski-Harabasz et Davies-Bouldin sur la matrice complète.*

Model	Silhouette (cos)	Calinski-Harabasz	Davies-Bouldin
BERTOPIC	-0.0282	277.1	11.2324
LDA	-0.0276	219.4	11.2640
IRAMUTEQ	-0.0307	204.3	14.2574

Ratio de séparation $SR = \text{inter/intra}$ (agrégation $n=11$). $SR > 1$: distances entre classes supérieures aux distances intra-classe.

Model	n=8	n=11
BERTOPIC	1.4018	1.5430
LDA	1.3052	1.4196
IRAMUTEQ	1.3071	1.4313




Figure 27: Semantic aggregation curve — camembert

Model	n=8	n=11
BERTOPIC	1.5920	1.8234
LDA	1.5057	1.6948
IRAMUTEQ	1.5071	1.6958




Figure 28: Semantic aggregation curve — solon

Espace : solon — circulaire pour BERTopic *Qualité de clustering (indices internes). Silhouette cosinus sur échantillon stratifié ; Calinski-Harabasz et Davies-Bouldin sur la matrice complète.*

Model	Silhouette (cos)	Calinski-Harabasz	Davies-Bouldin
BERTOPIC	-0.0099	377.2	8.9252
LDA	-0.0219	226.7	11.6015
IRAMUTEQ	-0.0173	219.7	13.6701

Ratio de séparation $SR = \text{inter/intra}$ (agrégation $n=11$). $SR > 1$: distances entre classes supérieures aux distances intra-classe.

Model	n=8	n=11
BERTOPIC	1.5365	1.7209
LDA	1.2935	1.4068
IRAMUTEQ	1.3158	1.4376

4. Synthèse et Conclusions

Principales Conclusions

Q1 — Accord entre modèles : L'accord le plus fort est observé entre lda vs iramuteq ($NMI = 0.2050$), tandis que bertopic vs lda montrent l'accord le plus faible ($NMI =$

0.1618). Ces valeurs modérées à faibles confirment que chaque modèle capture des aspects distincts du corpus.

Q2 — Séparation des artistes : IRAMUTEQ capture le mieux les signatures artistiques (V de Cramér = 0.3854, 12.2% de spécialistes).

Q3 — Dynamique temporelle : IRAMUTEQ montre la variance temporelle la plus élevée (0.001917), le rendant plus sensible à l'évolution du genre.

Q4 — Chevauchement lexical : Le Jaccard vocabulaire complet entre BERTopic et LDA varie de 0.4412 (seuil=1, vocabulaire fonctionnel partagé) à des valeurs plus faibles aux seuils supérieurs (seuil=5 : 0.5046), confirmant la divergence sur le vocabulaire spécialisé.

Q5 — Homogénéité intra-topic : BERTOPIC présente la meilleure homogénéité lexicale (Labbé = 0.9738), BERTOPIC la meilleure homogénéité distributionnelle (JS = 0.8171).

χ^2/n — Dépendance mot-topic : IRAMUTEQ montre la plus forte association mot-topic (χ^2/n = 1.3356), indiquant des topics lexicalement plus distinctifs.

Complémentarité des approches : Les trois modèles capturent des aspects distincts du corpus : - **BERTopic** : similarité sémantique via embeddings neuronaux - **LDA** : co-occurrences de mots via modèle génératif probabiliste - **IRAMUTEQ** : mondes lexicaux via classification hiérarchique descendante (ALCESTE)

L'utilisation conjointe de ces trois approches fournit une caractérisation multi-dimensionnelle du corpus, chaque modèle éclairant des facettes complémentaires de la structure thématique.

5. Références Méthodologiques

Métriques d'Accord de Clustering

- Hubert, L., & Arabie, P. (1985). Comparing partitions. *Journal of Classification*, 2(1), 193-218.
- Strehl, A., & Ghosh, J. (2002). Cluster ensembles: A knowledge reuse framework. *Journal of Machine Learning Research*, 3, 583-617.
- Vinh, N. X., Epps, J., & Bailey, J. (2010). Information theoretic measures for clusterings comparison: Variants, properties, normalization and correction for chance. *Journal of Machine Learning Research*, 11, 2837-2854.

Mesures d'Association

- Cramér, H. (1946). *Mathematical Methods of Statistics*. Princeton University Press.

Théorie de l'Information

- Lin, J. (1991). Divergence measures based on the Shannon entropy. *IEEE Transactions on Information Theory*, 37(1), 145-151.

Distance Intertextuelle

- Labbé, D., & Labbé, C. (2001). Inter-textual distance and authorship attribution. *Corela : cognition, représentation, langage. Journal of Quantitative Linguistics*, 8(3), 213-231.
- Labbé, D., & Monière, D. (2003). *Le vocabulaire gouvernemental : Canada, Québec, France (1945-2000)*. Honoré Champion.
- Labbé, C., & Labbé, D. (2007). Experiments on authorship attribution by intertextual distance in English. *Journal of Quantitative Linguistics*, 14(1), 33-80.
- IRAMUTEQ implementation: gitlab.huma-num.fr/pratinaud/iramuteq (distance-labbe.R)

Cohérence des Topics

- Röder, M., Both, A., & Hinneburg, A. (2015). Exploring the space of topic coherence measures. In *Proceedings of the Eighth ACM International Conference on Web Search and Data Mining (WSDM)*, 399-408.

Validation de Clusters

- Rousseeuw, P. J. (1987). Silhouettes: A graphical aid to the interpretation and validation of cluster analysis. *Journal of Computational and Applied Mathematics*, 20, 53-65.

Modélisation de Topics

- Grootendorst, M. (2022). BERTopic: Neural topic modeling with a class-based TF-IDF procedure. *arXiv preprint arXiv:2203.05794*.
- Blei, D. M., Ng, A. Y., & Jordan, M. I. (2003). Latent Dirichlet Allocation. *Journal of Machine Learning Research*, 3, 993-1022.
- Reinert, M. (1983). Une méthode de classification descendante hiérarchique : application à l'analyse lexicale par contexte. *Les Cahiers de l'Analyse des Données*, 8(2), 187-198.

Annexes

A. Détails des Runs

- **Timestamp de comparaison:** 2026-07-06 22:37:13
- **Dossier BERTopic:** results/BERTopic/run_20260706_220123_solon
- **Dossier LDA:** results/LDA/run_20260706_171018_both
- **Dossier IRAMUTEQ:** results/IRAMUTEQ/evaluation_20260126_124001

B. Comparaison Mathématique : Labbé vs Jensen-Shannon

Labbé vs Jensen-Shannon : deux regards sur les fréquences fondamentales

Les deux métriques mesurent la similarité lexicale entre textes mais avec des approches différentes.

Distance de Labbé (algorithme IRAMUTEQ) La distance de Labbé, implémentée selon l'algorithme original d'IRAMUTEQ, gère explicitement l'asymétrie de longueur entre textes. L'algorithme procède comme suit :

1. **Identifier** le texte le plus petit (N_{small}) et le plus grand (N_{large})
2. **Normaliser** les comptages du texte plus grand : $n'_i = n_i \times U$ où $U = N_{small}/N_{large}$
3. **Calculer** la somme des différences absolues sur les comptages normalisés
4. **Normaliser** par le dénominateur ajusté

$$D_{\text{Labbé}}(A, B) = \frac{\sum_{i=1}^V |n_{small}(i) - n'_{large}(i)|}{N_{small} + \sum_{n'_i \geq 1} n'_i}$$

Cette approche est particulièrement adaptée à la comparaison de textes de longueurs différentes.

Divergence de Jensen-Shannon Mesure la divergence informationnelle entre les distributions de probabilité.

$$D_{\text{JS}}(A, B) = \frac{1}{2}D_{\text{KL}}(P_A \| M) + \frac{1}{2}D_{\text{KL}}(P_B \| M)$$

où $M = (P_A + P_B)/2$ est la distribution moyenne et P représente les fréquences relatives.

Différence fondamentale

Aspect	Labbé	Jensen-Shannon
Entrée	Comptages bruts normalisés	Fréquences relatives
Asymétrie	Gère explicitement	Symétrique
Sensibilité	Linéaire	Logarithmique
Mots rares	Faible impact	Fort impact
Fondement	Algorithme IRAMUTEQ	Théorie de l'information

Application au rap français JS est plus sensible aux mots d'argot spécifiques à certains artistes/thèmes. **Labbé capture mieux l'homogénéité globale** du vocabulaire courant et gère mieux les différences de longueur entre couplets.

Recommandation : Utiliser les deux métriques en complément : - **Labbé** pour l'homogénéité lexicale générale (robuste aux différences de longueur) - **JS** pour détecter les vocabulaires distinctifs